دانشکده مهندسی مکانیک

پردیس دانشکده‌های فنی

دانشگاه تهران

هوش مصنوعی – نیمسال دوم ۴-۱۴۰۳

تمرین دوم

(رگرسیون)

نگارش:

علی خیری

۸۱۰۶۰۳۰۷۱

استاد درس:

دکتر شریعت‌پناهی

بهار ۱۴۰۴

۱- خوانش و تحلیل اکتشافی داده – Reading the Data and EDA ۳

۱-۱ خوانش داده‌ها ۳

۱-۲ مدیریت داده‌های پرت - Outliers ۴

۱-۳ مدیریت داده‌های ناموجود – Missing Values ۶

۱-۴ انجام تحلیل آماری ۸

۲- پیش‌پردازش و انتخاب ویژگی‌ها - Preprocessing the Data and Feature Selection ۱۰

۲-۱ نمایش ویژگی‌های مهم با معیار همبستگی پیرسون ۱۰

۲-۲ انتخاب ویژگی‌های مهم با SelectKBest ۱۳

۳- آموزش مدل‌های رگرسیون ۱۴

۳-۱ آموزش ۴ مدل... ..... ۱۵

۳-۲ تنظیم هایپرپارامترها برای بهترین مدل - HyperParameter Tuning ۱۶

۴- توضیح معیارهای RMSE و R-Squared ۱۸

۴-۱ MSE و RMSE ۱۸

۴-۲ R-Squared..... ۱۸

۵- Bias Variance Tradeoff ۲۰

۱- خوانش و تحلیل اکتشافی داده – Reading the Data and EDA

هدف اصلی تحلیل اکتشافی داده‌ها درک عمیق داده‌ها است. این فرآیند شامل خواندن داده‌ها، تلاش برای درک ویژگی‌هایی که بر داده‌ها تأثیر می‌گذارند، بررسی اندازه مجموعه داده و اطلاعات متعدد دیگری است که می‌توانند بعداً ما را در انجام مهندسی داده و انتخاب ویژگی بهینه هدایت کنند. این فرآیند ضروری است تا در بخش تحلیل رگرسیون به نتایج بهتری دست یابیم.

اهداف اصلی این بخش

۱. خواندن داده‌ها با استفاده از متد .info

۲. شناسایی و حذف داده‌های پرت

۳. مدیریت مقادیر گمشده

۴. انجام تحلیل آماری

۱-۱ خوانش داده‌ها

برای تحلیل اولیه داده‌ها می توان از دو متد head, info موجود در پانداس استفاده کرد. با دقت در این نتایج می توان اطلاعاتی مانند تعداد داده‌ها، ویژگی‌ها یا Features، نوع داده‌ها، تعداد مقادیر ناموجود برای هر ستون و اطلاعات دیگر را دریافت کرد. نتایج این داده‌ها بشرح زیر می‌باشد:

	Order	PID	MS SubClass	MS Zoning	Lot Frontage	Lot Area	Street	Alley	Lot Shape	Land Contour	...	Pool Area	Pool QC	Fence	Misc Feature	Misc Val	Mo Sold	Yr Sold	Sale Type	Sale Condition
0	1	526301100	20	RL	141.0	31770	Pave	NaN	IR1	Lvl	...	0	NaN	NaN	NaN	0	5	2010	WD	Normal
1	2	526350040	20	RH	80.0	11622	Pave	NaN	Reg	Lvl	...	0	NaN	MnPrv	NaN	0	6	2010	WD	Normal
2	3	526351010	20	RL	81.0	14267	Pave	NaN	IR1	Lvl	...	0	NaN	NaN	Gar2	12500	6	2010	WD	Normal
3	4	526353030	20	RL	93.0	11160	Pave	NaN	Reg	Lvl	...	0	NaN	NaN	NaN	0	4	2010	WD	Normal
4	5	527105010	60	RL	74.0	13830	Pave	NaN	IR1	Lvl	...	0	NaN	MnPrv	NaN	0	3	2010	WD	Normal
5	6	527105030	60	RL	78.0	9978	Pave	NaN	IR1	Lvl	...	0	NaN	NaN	NaN	0	6	2010	WD	Normal
6	7	527127150	120	RL	41.0	4920	Pave	NaN	Reg	Lvl	...	0	NaN	NaN	NaN	0	4	2010	WD	Normal
7	8	527145080	120	RL	43.0	5005	Pave	NaN	IR1	HLS	...	0	NaN	NaN	NaN	0	1	2010	WD	Normal
8	9	527146030	120	RL	39.0	5389	Pave	NaN	IR1	Lvl	...	0	NaN	NaN	NaN	0	3	2010	WD	Normal
9	10	527162130	60	RL	60.0	7500	Pave	NaN	Reg	Lvl	...	0	NaN	NaN	NaN	0	6	2010	WD	Normal

10 rows × 82 columns

شکل ۱-۱ اطلاعات کلی داده‌ها

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2930 entries, 0 to 2929
Data columns (total 82 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   Order            2930 non-null   int64
 1   PID              2930 non-null   int64
 2   MS SubClass      2930 non-null   int64
 3   MS Zoning        2930 non-null   object
 4   Lot Frontage     2440 non-null   float64
 5   Lot Area         2930 non-null   int64
 6   Street           2930 non-null   object
 7   Alley            198 non-null    object
 8   Lot Shape        2930 non-null   object
 9   Land Contour     2930 non-null   object
 10  Utilities        2930 non-null   object
 11  Lot Config       2930 non-null   object
 12  Land Slope       2930 non-null   object
 13  Neighborhood     2930 non-null   object
 14  Condition 1      2930 non-null   object
 15  Condition 2      2930 non-null   object
 16  Bldg Type        2930 non-null   object
 17  House Style      2930 non-null   object
 18  Overall Qual     2930 non-null   int64
 19  Overall Cond     2930 non-null   int64
...
 80  Sale Condition   2930 non-null   object
 81  SalePrice        2930 non-null   int64
dtypes: float64(11), int64(28), object(43)
memory usage: 1.8+ MB
```

شکل ۱-۲ اطلاعات کلی داده با با متد info

۱-۲ مدیریت داده‌های پرت - Outliers

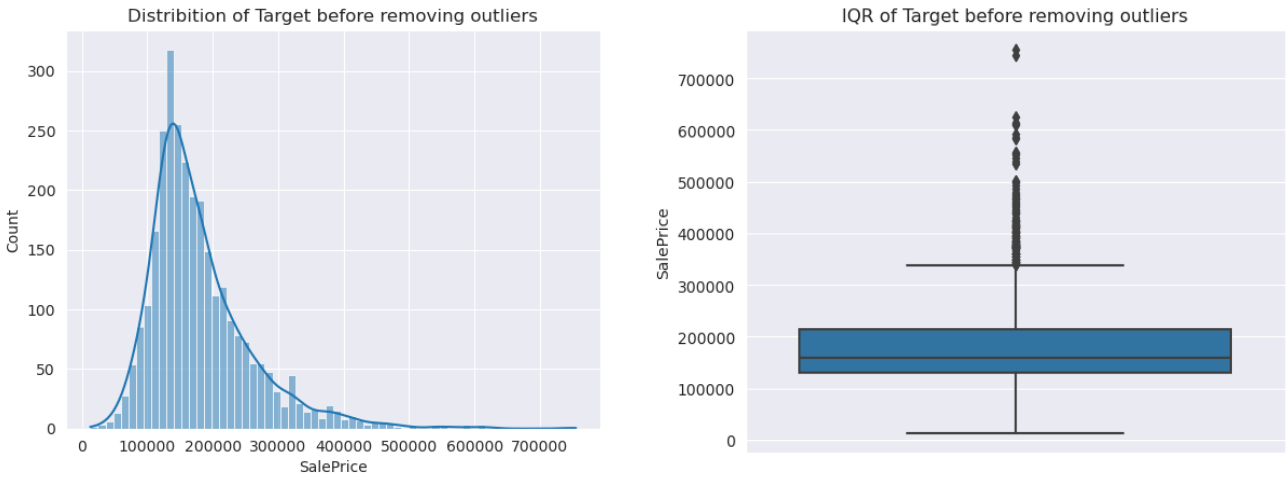
مدیریت داده‌های پرت در سه مرحله انجام می‌شود:

۱. **نمایش بصری توزیع متغیر هدف یا SalePrice با استفاده از هیستوگرام و نمودار جعبه‌ای**:
از هیستوگرام (histplot) و نمودار جعبه‌ای (boxplot) برای بررسی توزیع SalePrice استفاده می‌شود.

۲. **محاسبه تعداد داده‌های پرت با استفاده از روش IQR**
با استفاده از روش بازه بین‌چارک‌ها یا IQR داده‌های پرت شناسایی و تعداد آن‌ها محاسبه می‌شود.

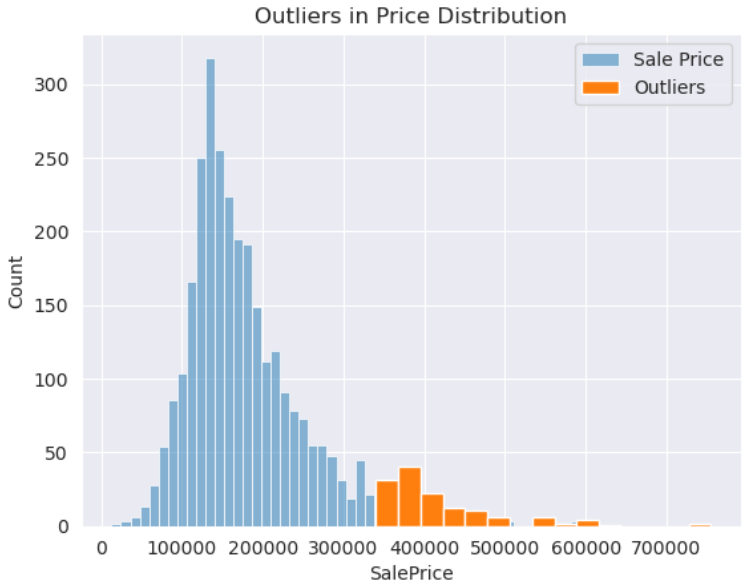
۳. **نمایش بصری توزیع متغیر هدف پس از حذف داده‌های پرت**
پس از حذف داده‌های پرت، توزیع SalePrice مجدداً با استفاده از هیستوگرام و نمودار جعبه‌ای بررسی می‌شود.

نکته مهم: ممکن است ویژگی‌های دیگر نیز شامل داده‌های پرت باشند، اما حذف آن‌ها ممکن است لازم نباشد، زیرا حذف ردیف‌هایی که حاوی داده‌های پرت در SalePrice هستند، به احتمال زیاد داده‌های پرت مرتبط با سایر ویژگی‌ها را نیز حذف خواهد کرد.



شکل ۱-۳ توزیع داده‌های قیمت – همانطور که از نمودار جعبه‌ای مشخص است تعداد قابل توجهی از داده‌ها خارج از ۴ چارک اصلی می‌باشند

معیار پرت بودن داده‌ها با استفاده از روش IQR تعیین می‌شود. به این صورت که اگر جایگاه داده خارج از ۱,۵ برابری چارک‌های اول و چهارم باشد، داده بصورت پرت درنظر گرفته می‌شود. با محاسبه این مقادیر، نمودار هیستوگرام شامل مقادیر پرت بصورت زیر می‌باشد:



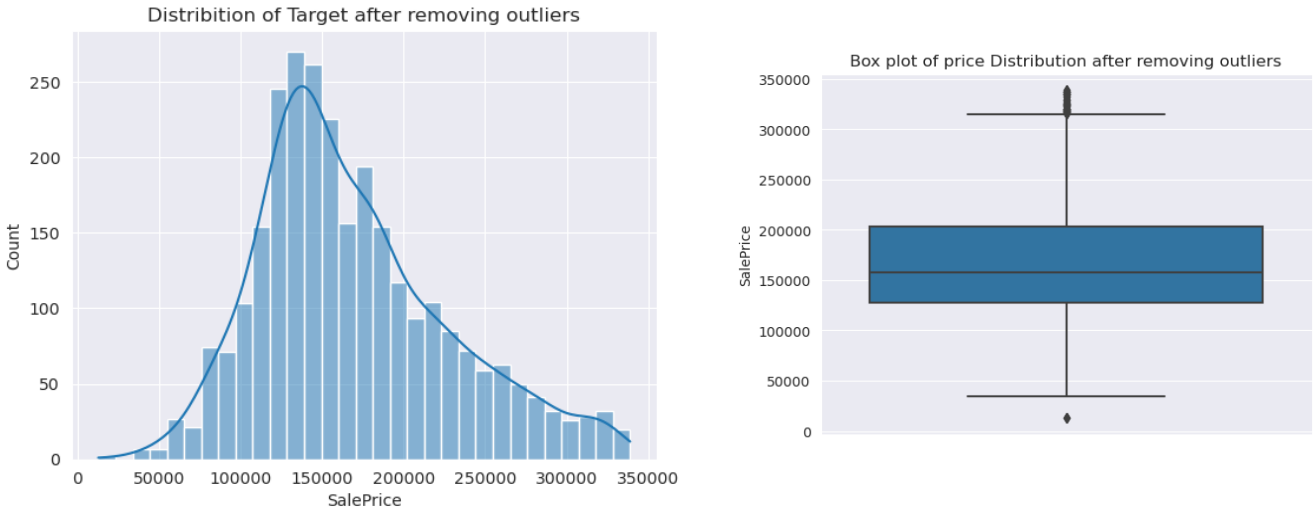
شکل ۱-۴ توزیع داده‌های پرت – همانطور که مشخص است تعداد کمی از خانه ها قیمتی بسیار بالا داشته و داده پرت به حساب می‌آیند.

با محاسبات انجام شده، تعداد این داده‌ها بصورت زیر مشخص خواهدشد:

```
Q1: 129500.0
Q3: 213500.0
IQR: 84000.0
Lower Bound: 3500.0
Upper Bound: 339500.0
Number of Outliers: 137
```

شکل ۱-۵ مشخصات چارک‌ها و تعداد داده‌های پرت

با حذف این تعداد از داده‌ها، هیستوگرام و نمودار جعبه‌ای قیمت خانه به شرح زیر می‌باشد:



شکل ۱-۶ توزیع داده‌های قیمت خانه پس از حذف داده‌های پرت

۱-۳ مدیریت داده‌های ناموجود – Missing Values

این بخش شامل ۳ مرحله است:

۱- تشخیص و خلاصه‌سازی مقادیر گم‌شده برای هر ویژگی:

شناسایی و جمع‌بندی مقادیر (Missing Values) برای هر ستون

۲- جایگزینی مقادیر گم‌شده:

برای **ستون‌های دسته‌ای (Categorical):** جایگزینی با پرتکرارترین مقدار (مُد)

برای **ستون‌های عددی :(Numerical)** جایگزینی با میانه (میانگین)

برای ستون‌هایی که مقادیر گم‌شده نشان‌دهنده **عدم وجود** هستند مثلاً Alley = NA با "None"جایگزین خواهدشد.

۳- اعتبارسنجی نهایی:

اطمینان از عدم وجود مقادیر گم‌شده باقی‌مانده در مجموعه

اطلاعات ستون‌های دارای مقدار ناموجود به شرح زیر می‌باشد:

```
Columns with Missing Values:
                Missing Values  Percentage (%)
Lot Frontage               485       17.364841
Alley                     2596       92.946652
Mas Vnr Type              1754       62.799857
Mas Vnr Area                21        0.751880
Bsmt Qual                   80        2.864304
Bsmt Cond                   80        2.864304
Bsmt Exposure               83        2.971715
BsmtFin Type 1              80        2.864304
BsmtFin SF 1                 1        0.035804
BsmtFin Type 2              81        2.900107
BsmtFin SF 2                 1        0.035804
Bsmt Unf SF                  1        0.035804
Total Bsmt SF                1        0.035804
Electrical                   1        0.035804
Bsmt Full Bath               2        0.071608
Bsmt Half Bath               2        0.071608
Fireplace Qu              1420       50.841389
Garage Type                157        5.621196
Garage Yr Blt              159        5.692803
Garage Finish              159        5.692803
Garage Cars                  1        0.035804
Garage Area                  1        0.035804
Garage Qual                159        5.692803
...
Misc Feature              2687       96.204798

Total Missing Values: 15180
Percentage of Total Missing Values: 6.63%
```

شکل ۱-۷ تعداد داده‌های ناموجود و درصد آن برای هر ستون

همانطور که مشاهده می‌شود برخی ستون‌ها مانند Alley دارای تعداد بسیار زیادی مقدار ناموجود بوده و به احتمال زیاد جزو ویژگی‌های مهم برای تعیین خانه به حساب نمی‌آیند.

پس از مدیریت مقادیر ناموجود برای ستون‌های عددی و دسته‌ای با روش گفته شده، صحت‌سنجی می‌شود که هیچ داده ناموجود در سطرها موجود نخواهد بود.

	Missing Count	Missing Percentage
Order	0	0.0
PID	0	0.0
MS SubClass	0	0.0
MS Zoning	0	0.0
Lot Frontage	0	0.0
...	...	...
Mo Sold	0	0.0
Yr Sold	0	0.0
Sale Type	0	0.0
Sale Condition	0	0.0
SalePrice	0	0.0

[82 rows x 2 columns]
Total number of Missing values 0

شکل ۱-۸ صحت‌سنجی عدم وجود داده ناموجود پس از مدیریت آنها

با حذف داده‌های پرت و مدیریت داده‌های ناموجود، بخش بزرگی از پیش-پردازش داده‌ها نیز انجام شده تا آموزش مدل رگرسیون در ادامه راحت‌تر باشد.

۱-۴ انجام تحلیل آماری

در این بخش از متد داخلی ()describe در کتابخانه پانداس استفاده می‌شود تا اطلاعات مورد نیاز جمع‌آوری شود.

۱- برای ستون‌های عددی:

اطلاعاتی مانند حداقل مقدار(min)، حداکثر مقدار(max)، انحراف معیار (std) و سایر آماره‌ها نمایش داده می‌شود.

۲- برای ستون‌های دسته‌ای:

تعداد مقادیر منحصر به فرد (Number of Unique Values) در هر ستون نشان داده می‌شود.

Statistical Analysis for numerical columns:

	Order	PID	MS SubClass	Lot Frontage	Lot Area	\
count	2793.000000	2.793000e+03	2793.000000	2793.000000	2793.000000	
mean	1468.024705	7.208481e+08	58.011099	67.811672	9856.793770	
std	847.676194	1.886559e+08	43.144351	20.674210	6816.410052	
min	1.000000	5.263011e+08	20.000000	21.000000	1300.000000	
25%	735.000000	5.313851e+08	20.000000	60.000000	7313.000000	
50%	1462.000000	9.021021e+08	50.000000	67.000000	9259.000000	
75%	2196.000000	9.071941e+08	70.000000	76.000000	11227.000000	
max	2930.000000	1.007100e+09	190.000000	313.000000	164660.000000	

	Overall Qual	Overall Cond	Year Built	Year Remod/Add	Mas Vnr Area	\
count	2793.000000	2793.000000	2793.000000	2793.000000	2793.000000	
mean	5.963838	5.585034	1969.900823	1983.306839	85.640172	
std	1.300120	1.124431	30.049813	20.856293	155.184128	
min	1.000000	1.000000	1872.000000	1950.000000	0.000000	
25%	5.000000	5.000000	1952.000000	1964.000000	0.000000	
50%	6.000000	5.000000	1971.000000	1991.000000	0.000000	
75%	7.000000	6.000000	1999.000000	2003.000000	140.000000	
max	10.000000	9.000000	2010.000000	2010.000000	1600.000000	

	...	Wood Deck SF	Open Porch SF	Enclosed Porch	3Ssn Porch	\
count	...	2793.000000	2793.000000	2793.000000	2793.000000	
...						
75%	202900.000000					
max	338931.000000					

شکل ۱-۹ تحلیل آماری برای داده‌های عددی

Number of Unique Values in Categorical Columns:

MS Zoning	7
Street	2
Alley	3
Lot Shape	4
Land Contour	4
Utilities	3
Lot Config	5
Land Slope	3
Neighborhood	28
Condition 1	9
Condition 2	8
Bldg Type	5
House Style	8
Roof Style	6
Roof Matl	8
Exterior 1st	16
Exterior 2nd	17
Mas Vnr Type	4
Exter Qual	4
Exter Cond	5
Foundation	6
...	
Misc Feature	6
Sale Type	10
Sale Condition	6

شکل ۱-۱۰ تحلیل آماری برای داده‌های دسته‌ای

با انجام این بخش بخش اول تمرین به پایان می‌رسد.

۲- پیش-پردازش و انتخاب ویژگی‌ها - Preprocessing the Data and Feature Selection

۲-۱ نمایش ویژگی‌های مهم با معیار همبستگی پیرسون

برای یافتن ویژگی‌های مهم‌تر، نیاز است که همبستگی پیرسون یا Pearson Correlation بین هر یک از ویژگی‌های عددی و متغیر هدف که SalePrice می‌باشد، محاسبه شود. این کار در ۴ مرحله انجام می‌شود:

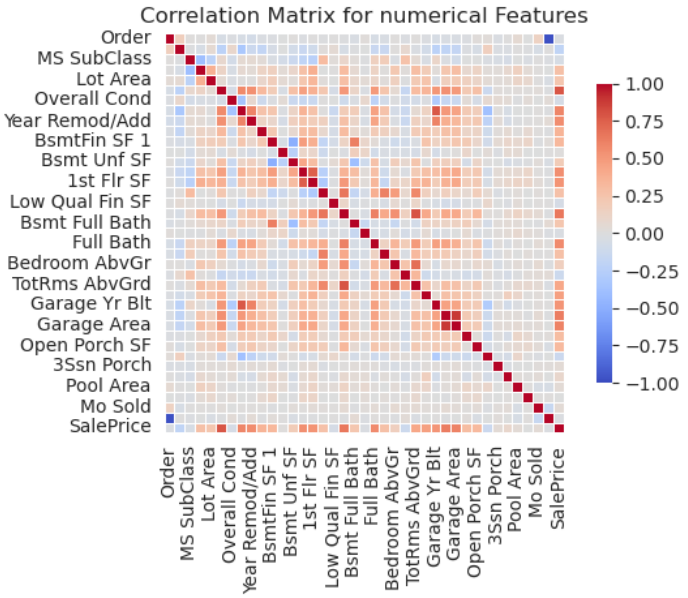
۱. محاسبه همبستگی‌های پیرسون برای ویژگی‌های مختلف

۲. مصورسازی ماتریس همبستگی با استفاده از هیت‌مپ – Correlation Matrix

۳. رتبه‌بندی ویژگی‌ها بر اساس میزان ارتباط با متغیر هدف (چه مثبت و چه منفی) - در این مثال ۶ ویژگی برتر در نظر گرفته شده‌است.

۴. مصورسازی ویژگی‌های مهم‌تر با نمودار JointPlot

با محاسبه ماتریس همبستگی بین ویژگی‌های مختلف، ماتریس زیر رسم خواهد شد:



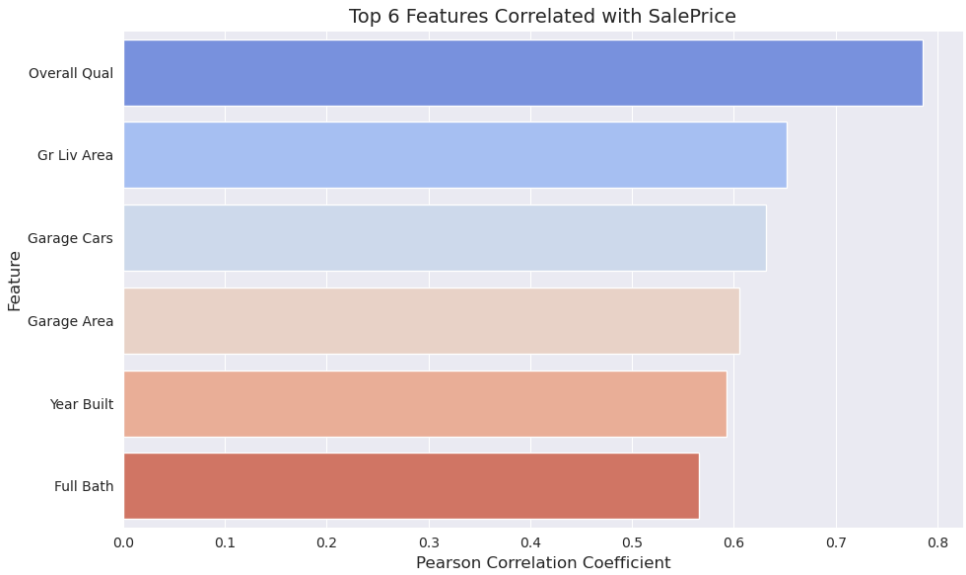
شکل ۲-۱ ماتریس همبستگی بین ویژگی‌های مختلف

با داشتن ماتریس همبستگی و مرتب‌سازی آنها (بر اساس قدرمطلق مقدار آنها)، ویژگی‌هایی که بیشترین ارتباط را با قیمت خانه داشته و بیشترین تاثیر را بر آن دارند مشخص می‌شوند. به جهت نمایش بهتر، ۶ ویژگی برتر از میان حدود ۸۰ ویژگی به عنوان ویژگی‌های مهم شناخته شده‌اند.

```
Top 10 Features Correlated with SalePrice:
Overall Qual    0.785878
Gr Liv Area     0.652255
Garage Cars     0.631196
Garage Area     0.605585
Year Built      0.592549
Full Bath       0.565246
```

شکل ۲-۱ شش ویژگی که بیشترین تاثیر را بر قیمت خانه دارند.

همانطور که مشخص است ویژگی‌های مهمی مانند کیفیت کلی، مساحت، تعداد ماشین‌های موجود در خانه تاثیر بسزایی در قیمت نهایی خانه دارند.



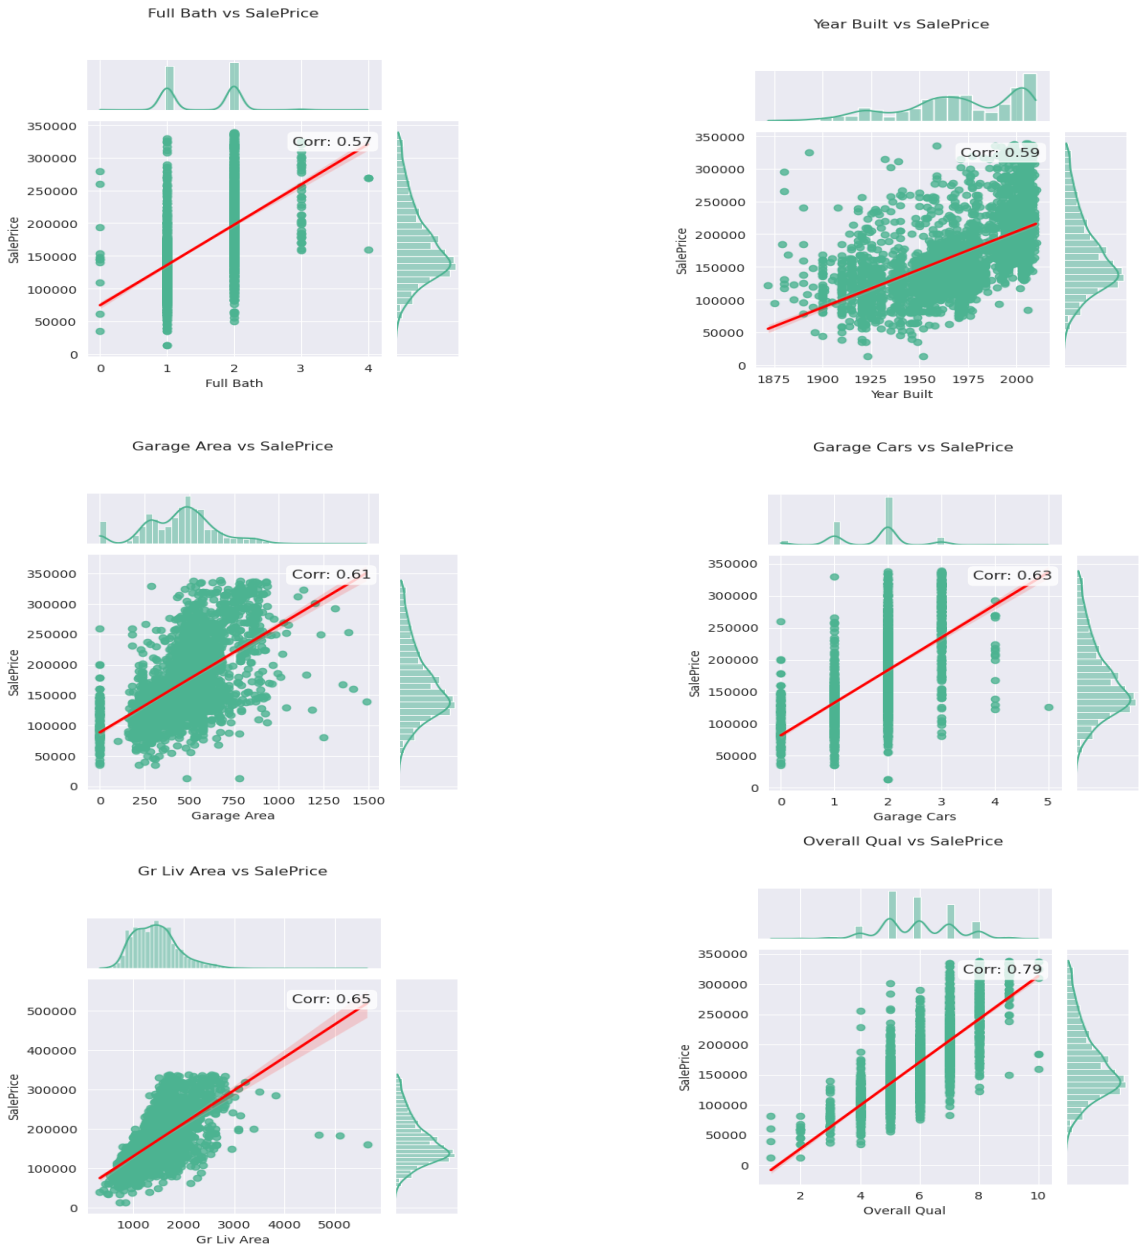
شکل ۱-۳ ویژگی‌های مهم به همراه مقدار همبستگی

هرچند این روش آماری بسیار کارآمد است، روش همبستگی پیرسون دارای دو ایراد می‌باشد:

۱- ستون‌های دارای مقادیر دسته‌ای یا Categorical Columns در این روش لحاظ نمی‌شوند.

۲- تنها رابطه خطی بین ویژگی‌ها در نظر گرفته می‌شود و برای مثال اگر جنس همبستگی بین ویژگی‌ها از نوع نمایی باشد در نظر گرفته نمی‌شود.

در ادامه jointplot این ۶ ویژگی مهم رسم می شود. این نمودار توزیع هر دو ویژگی را در یک نمودار رسم کرده و پراکندگی داده‌ها را به صورت Scatter Plot نمایش می‌دهد و یک نمایش مفید برای درک روابط بین ویژگی‌ها به‌شمار می‌رود.



شکل ۱-۴ JointPlot ویژگی‌های مهم

۲-۲ انتخاب ویژگی‌های مهم با SelectKBest

برای تعیین بهترین ویژگی‌ها از روش **SelectKBest** با استفاده از آزمون ساده f_regression استفاده خواهیم کرد. پیش از این کار، نیاز است داده‌ها را تبدیل یا Transform کنیم. مراحل به شرح زیر است:

۱ -پیش‌پردازش داده‌های دسته‌ای با استفاده از (One-Hot Encoding)

این مرحله حیاتی است زیرا آموزش مدل فقط با مقادیر عددی امکان‌پذیر است.

۲- توازن عددی یا Scaling با استفاده از StandardScaler

این کار باعث می‌شود تمام داده‌های عددی در محدوده ۱+ تا ۱- قرار بگیرند.

۳ -تعریف ماتریس ویژگی‌ها (X) و متغیر هدف(Y)

۴ -انتخاب بهترین ویژگی‌ها بر اساس SelectKBest با معیار f_regression

در این روش، مدل رگرسیون خطی ساده با تعداد مختلفی از ویژگی‌ها (K) آموزش داده می‌شود تا مشخص شود کدام مدل نتایج بهتری دارد.

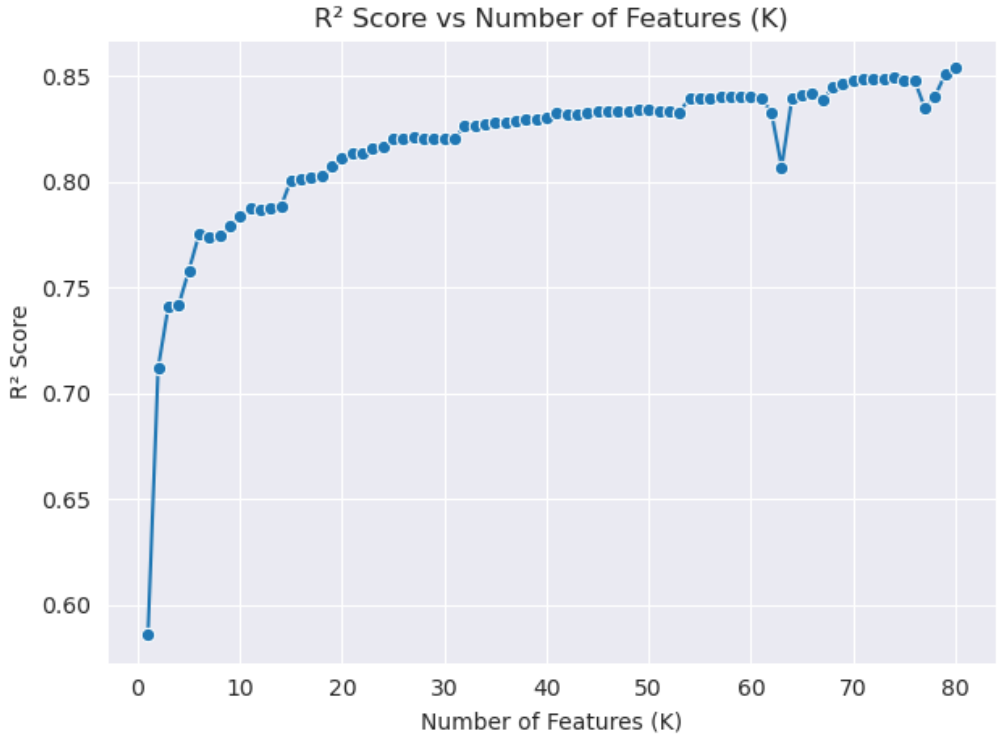
معیار مقایسه مدل‌ها در این بخش **ضریب تعیین (R-Squared)** است.

پس از پیش‌پردازش داده‌ها، دیتافریم جدید با حفظ ماهیت اصلی تغییر شکل خواهد داد:

	PID	Lot Frontage	Lot Area	Overall Qual	Year Built	Year Remod/Add	Mas Vnr Area	BsmtFin SF 1	Bsmt Unf SF	Total Bsmt SF	...	Garage Qual_Fa	Garage Qual_None	Garage Qual_TA	Garage Cond_None	Garage Cond_TA	Paved Drive_N	Paved Drive_Y
0	-1.031412	3.540712	3.215348	0.027819	-0.329539	-1.117697	0.169892	0.538896	-0.257696	0.163214	...	0.0	0.0	1.0	0.0	1.0	0.0	0.0
1	-1.031152	0.589648	0.259011	-0.741479	-0.296255	-1.069741	-0.551960	0.132431	-0.656209	-0.325581	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
2	-1.031147	0.638026	0.647114	0.027819	-0.396107	-1.213608	0.144112	1.213961	-0.339263	0.777910	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
3	-1.031136	1.218564	0.191221	0.797117	-0.063267	-0.734051	-0.551960	1.551493	1.149920	2.705932	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
4	-1.027150	0.299380	0.582993	-0.741479	0.901970	0.704621	-0.551960	0.900198	-0.966164	-0.212022	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2788	1.073188	-1.490610	-0.281693	0.027819	0.469278	0.033241	-0.551960	0.966754	-0.856631	-0.026873	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
2789	1.073194	-0.039267	-0.142592	-0.741479	0.435993	-0.014715	-0.551960	-0.264526	-0.728454	-0.370016	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
2790	1.073851	-0.281158	0.085721	-0.741479	0.735550	0.416887	-0.551960	-0.178955	0.054590	-0.251521	...	0.0	1.0	0.0	1.0	0.0	0.0	1.0
2791	1.077562	0.444514	0.022480	-0.741479	0.136437	-0.398361	-0.551960	1.565755	-0.830996	0.926029	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0
2792	1.077832	0.299380	-0.033718	0.797117	0.768834	0.512799	0.053880	0.821758	-0.730785	-0.044153	...	0.0	0.0	1.0	0.0	1.0	0.0	1.0

شکل ۱-۵ دیتافریم پس از پیش-پردازش داده‌ها – همانطور که مشخص است داده‌های عددی بین -۱ تا +۱ تقلیل داده شده و داده‌های دسته‌بندی به صورت عدد تبدیل شده‌اند.

با آموزش مدل با K های مختلف (تعداد ویژگی‌های مختلف)، نمودار دقت مدل با تعداد ویژگی‌های بدست می‌آید. همانطور که گفته شده معیار دقت مدل در این مرحله R-Squared و مدل استفاده شده یک مدل رگرسیون خطی ساده می‌باشد:



شکل ۱-۶ دقت مدل با تعداد ویژگی‌های مختلف

همانطور که از روند کلی نمودار مشخص است، با بیشتر شدن تعداد ویژگی‌ها، دقت مدل نیز بهتر شده و برای آموزش نهایی نیز، از تمام ویژگی‌ها استفاده شده‌است.

۳- آموزش مدل‌های رگرسیون

این بخش پایانی در تمرین اول است. پس از یافتن تعداد بهینه ویژگی‌ها (که شامل تمام ویژگی‌ها می‌شود) و پیش‌پردازش داده‌ها، زمان آن رسیده که مدل‌های رگرسیون را آموزش داده و ارزیابی کنیم. مراحل کار به شرح زیر است:

۱- تقسیم داده‌ها به بخش آموزش و تست با نسبت ۲۵ درصد

۲- آموزش ۴ مدل مختلف:

- رگرسیون خطی ساده(Linear Regression)
- رگرسیون لاسو (Lasso Regression) با مقدار آلفای از پیش تعیین شده برابر ۰,۱
- رگرسیون ریدج (Ridge Regression) با مقدار آلفای از پیش تعیین شده برابر ۱
- رگرسیون چندجمله‌ای (Polynomial Regression) با درجه2=n

۳- ارزیابی مدل‌ها با معیارهای زیر:

- میانگین خطای مطلق(MAE - Mean Absolute Error)
- میانگین مربعات خطا(MSE - Mean Squared Error)
- جذر میانگین مربعات خطا(RMSE - Root Mean Squared Error)
- ضریب تعیین(R Squared)

۴- مقایسه این ۴ مدل بر اساس معیارهای فوق و انتخاب بهترین مدل

۵- بهینه‌سازی بهترین مدل با تنظیم ابرپارامترها – HyperParameter Tuning

۳-۱ آموزش ۴ مدل

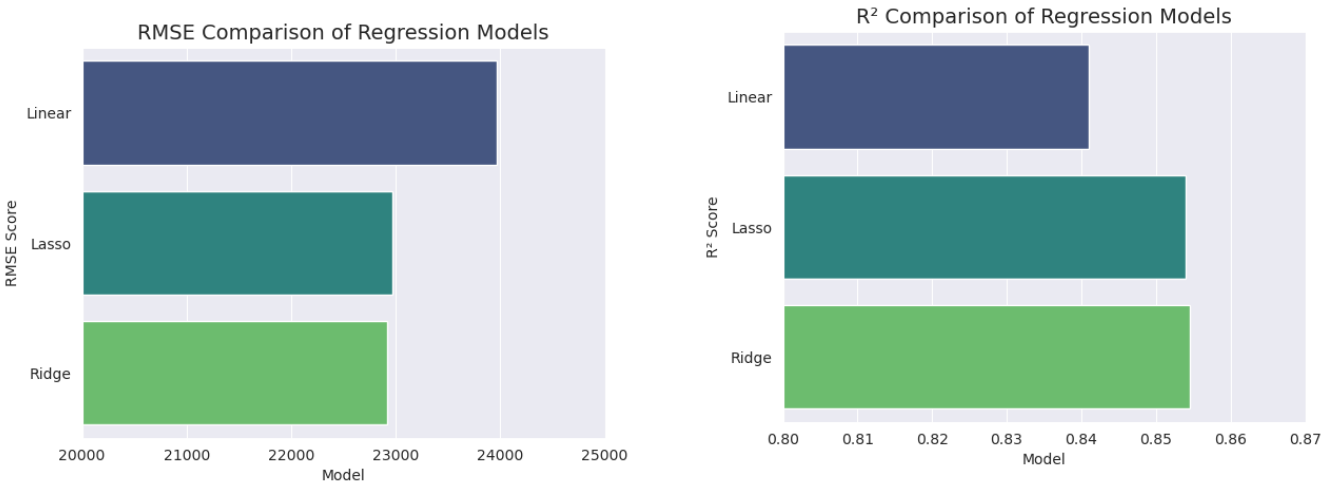
آز آنجا که پیش-پردازش داده‌ها در قسمت‌های قبلی انجام شده، تنها لازم است داده‌های نهایی به آموزش و تست با Randomseed(42) تقسیم شده و آموزش مدل‌ها انجام شود. با آموزش مدل‌ها، نتایج آنها به صورت زیر می‌باشد:

	Model	MSE	RMSE	MAE	R2
0	Linear	5.743825e+08	2.396628e+04	1.627997e+04	0.840937
1	Lasso	5.274121e+08	2.296545e+04	1.530611e+04	0.853944
2	Ridge	5.250362e+08	2.291367e+04	1.527754e+04	0.854602
3	Polynomial	3.545063e+14	1.882834e+07	8.022338e+06	-98172.088584

شکل ۳-۱ نتایج مدل‌های مختلف بر اساس معیارهای متفاوت

همانطور که مشخص است، رگرسیون چندجمله‌ای نسبت به سایر مدل‌ها بسیار ضعیف بوده و دلیل این امر می‌تواند پایین بودن درجه آن (۲) باشد و با امتحان کردن درجات مختلف، این مشکل می‌تواند تا حدی بهبود یابد.

مدل‌های لاسو و ریدج نتایجی بهتر و مشابه هم داشته و برای مقایسه دقیق آنها، از نمودار barplot استفاده شده تا معیارهای RMSE و R-Squared با هم مقایسه شوند:



شکل ۳-۲ مقایسه مدل‌های مختلف رگرسیون

همانطور که از نتایج مشخص است، مدل Ridge با اخلاف کمی از مدل Lasso بهتر بوده و به عنوان بهترین مدل انتخاب می‌شود.

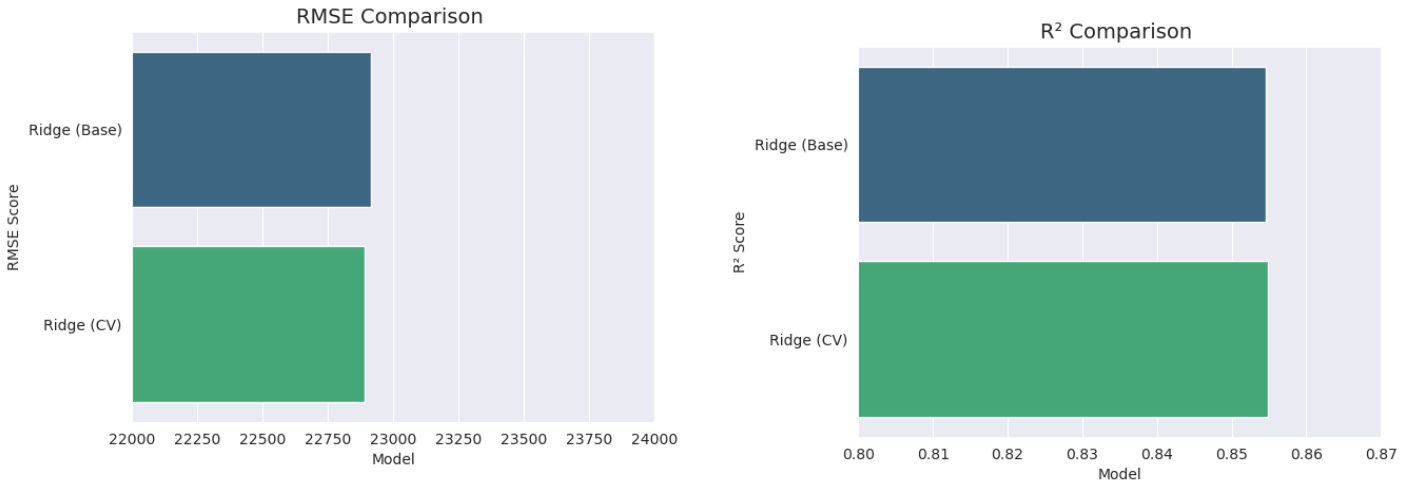
۳-۲ تنظیم هایپرپارامترها برای بهترین مدل - HyperParameter Tuning

در بخش نهایی، با روش GridSearchCV مقادیر مختلف آلفا آزمایش شده و مشخص می‌شود که کدام مقدار آن منجر به بهترین مدل می‌شود:

```
Best alpha selected by RidgeCV: 3.5564803062231287
```

شکل ۳-۳ مقدار آلفا بهینه

اکنون بار دیگر یک مدل Ridge با این مقدار آلفا آموزش داده شده و با مدل اولیه (آلفا = ۱) مقایسه می‌شود:



شکل ۳-۴ مقایسه مدل پایه Base با مدل بهینه شده CV

نتایج نشان می‌دهد که با انتخاب آلفا جدید، معیار R-Squared کمی بهتر شده و RMSE (که بیانگر خطا می‌باشد) کاهش یافته. این امر نشان می‌دهد که بهینه کردن مقدار آلفا موثر بوده و باعث بهبود نهایی برترین مدل می‌شود.

در مدل‌های یادگیری ماشین که شامل تعداد پارامترهای بیشتری بوده این بهبود تاثیر بیشتری نیز خواهدداشت.

۴- توضیح معیارهای RMSE و R-Squared

۴-۱ MSE و RMSE

MSE یا میانگین مربعات خطا با گرفتن میانگین مربع اختلاف بین مقادیر پیش‌بینی شده و مقادیر واقعی محاسبه می‌شود. این معیار یکی از پرکاربردترین معیارها برای مسائل رگرسیون است:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)$$

که در آن:

- n تعداد مشاهدات یا داده‌ها است.
- y بیانگر مقدار واقعی هدف است.
- $\hat{y}$ بیانگر مقدار پیش-بینی شده توسط مدل رگرسیون است.

RMSE به سادگی برابر با جذر MSE است. این معیار اغلب به MSE ترجیح داده می‌شود زیرا واحد آن با متغیر هدف یکسان است RMSE .به صورت زیر محاسبه می‌شود:

$$RMSE = \sqrt{MSE}$$

این معیارها قبلاً برای مدل‌های ما در بخش قبلی نوت‌بوک محاسبه شده‌اند.

۴-۲ R-Squared

در تحلیل رگرسیون، R-Squared به عنوان ضریب همبستگی شناخته می‌شود و به صورت رابطه یا همبستگی بین متغیر مستقل و وابسته تعریف می‌گردد. این ضریب در محدوده ۱- تا ۱+ قرار دارد. مقدار R برابر با ۱- نشان‌دهنده یک رابطه منفی کامل و مقدار ۱+ نشان‌دهنده یک رابطه مثبت کامل بین متغیر مستقل و وابسته است. بنابراین، مقدار صفر برای R نشان می‌دهد که هیچ رابطه‌ای بین این متغیرها وجود ندارد. بسته به نوع مطالعه

شما، هرچه مقدار R به ۱- یا ۱+ نزدیک‌تر باشد، نشان‌دهنده رابطه بهتر است. این ضریب معمولاً به صورت درصد بیان می‌شود.

این معیاری آماری است که نشان می‌دهد داده‌ها چقدر به خط رگرسیون برازش شده نزدیک هستند. این معیار با نام‌های ضریب تعیین یا ضریب تعیین چندگانه (در رگرسیون چندمتغیره) نیز شناخته می‌شود. تعریف R^2 نسبتاً ساده است: این معیار نشان‌دهنده درصد تغییرات متغیر پاسخ است که توسط مدل خطی توضیح داده می‌شود.

این معیار نشان‌دهنده نسبت واریانس در متغیر وابسته است که از طریق متغیر(های) مستقل قابل پیش‌بینی است. این معیار به صورت زیر محاسبه می‌شود:

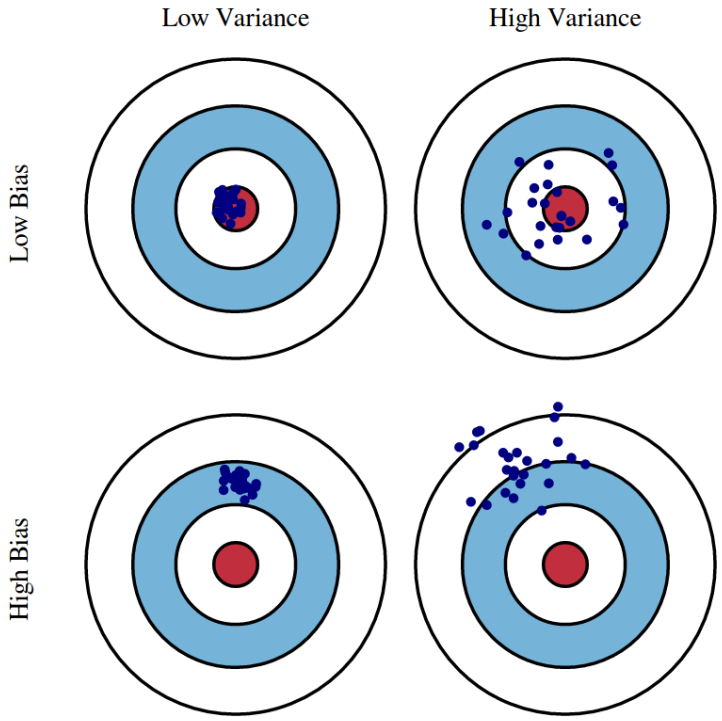
$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)}{\sum_{i=1}^{n}(y_i - \bar{y})} = 1 - \frac{var(error)}{var(Y)}$$

۵- Bias Variance Tradeoff

مبادله بایاس-واریانس (Bias-Variance Trade-off) یک مفهوم بنیادی در یادگیری ماشین است که چارچوبی برای درک خطای مدل و مسئله بیش‌برازش (Overfitting) ارائه می‌دهد. این مفهوم به ما کمک می‌کند بین پیچیدگی مدل و توانایی آن در تعمیم به داده‌های جدید تعادل برقرار کنیم. این مبادله در انتخاب مدل مناسب و اعمال تکنیک‌های تنظیم (Regularization) بسیار حیاتی است.

خطای پیش‌بینی یک مدل را می‌توان به دو جزء اصلی تقسیم کرد:

۱- بایاس Bias: خطای ناشی از تقریب یک مسئله واقعی با یک مدل ساده‌شده.
۲ واریانس Variance خطای ناشی از حساسیت مدل به نوسانات در داده‌های آموزشی.



شکل ۵-۱ نمایان شدن عدم وجود بایاس یا واریانس در مدل یادگیری ماشین

انواع خطاها و ویژگی‌های آنها:

۱- بایاس بالا یا Under Fitting

- علائم: عملکرد ضعیف هم روی داده‌های آموزشی و هم داده‌های آزمون
- ویژگی‌ها:
  - مدل بیش از حد ساده است و نمی‌تواند الگوی اصلی داده را تشخیص دهد
  - فرضیات قوی درباره توزیع داده دارد
  - مثال: استفاده از مدل‌های خطی برای روابط غیرخطی پیچیده

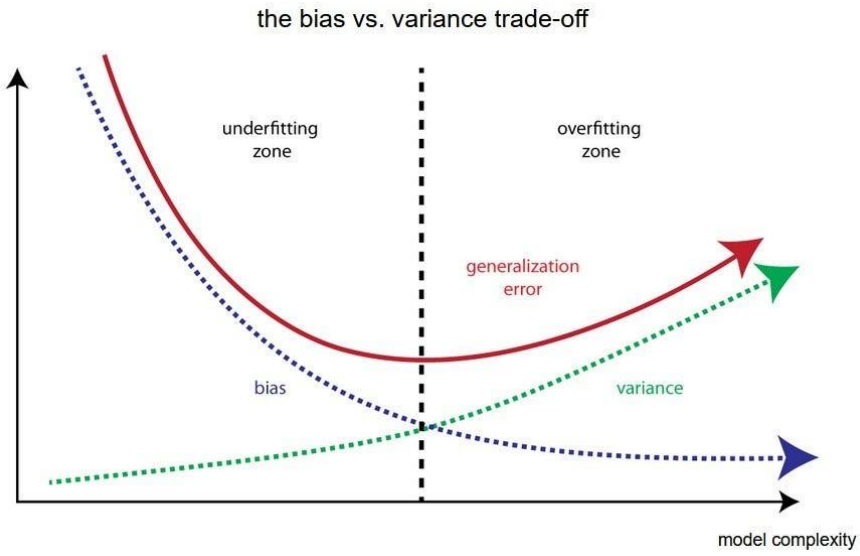
مثال :استفاده از رگرسیون خطی برای مدل‌سازی یک رابطه درجه دوم واضح منجر به بایاس بالا می‌شود.

۲- واریانس بالا یا Overfitting

- علائم: عملکرد عالی روی داده‌های آموزشی، عملکرد ضعیف روی داده‌های آزمون
- ویژگی‌ها:
  - مدل بیش از حد پیچیده است و نویزهای داده آموزشی را یاد می‌گیرد
  - به نوسانات کوچک در مجموعه آموزشی بسیار حساس است
  - مثال: مدل‌های چندجمله‌ای با درجه بالا، شبکه‌های عصبی عمیق با پارامترهای زیاد

مثال :برازش یک چندجمله‌ای با درجه بالا به مجموعه‌داده‌ای با تعداد نقاط کم معمولاً منجر به واریانس بالا می‌شود.

این دو مورد به طور کلی در شکل زیر نمایش داده است:



شکل ۵-۲ Bias Variance Tradeoff

مدل یادگیری ماشین قابل قبول خواهد بود که بتواند تعادل بین این دو را برقرار سازد.