دانشکده مهندسی مکانیک

پردیس دانشکده‌های فنی

دانشگاه تهران

هوش مصنوعی – نیمسال دوم ۴-۱۴۰۳

تمرین سوم

(دسته‌بندی)

نگارش:

علی خیری

۸۱۰۶۰۳۰۷۱

استاد درس:

دکتر شریعت‌پناهی

بهار ۱۴۰۴

۱- بررسی داده‌های خام – EDA ۳

۱-۱ خوانش و آشنایی اولیه با داده‌ها ۳

۱-۲ تحلیل و مدیریت مقادیر ناموجود ۵

۱-۳ تحلیل همبستگی برای یافتن ویژگی‌های مهم – Correlation Analysis ۶

۲- پیش‌پردازش دادهها – Data Preprocessing ۹

۲-۱ حذف مقادیر پرت ۹

۲-۲ فرآیندهای Normalize و Standardize ۱۰

۳- دسته‌بندی دوگانه ۱۳

۳-۱ بررسی و مدیریت عدم توازن داده‌ها – Unbalanced Data Analysis ۱۳

۳-۲ آموزش مدل‌ها و ارزیابی ۱۴

۳-۴ بهینه‌سازی پارامترها – Fine Tuning Hyperpatameters ۱۶

۳-۵ ارزیابی و مقایسه مدل‌ها ۱۷

۴- دسته‌بندی چندگانه ۱۸

۴-۱ آموزش مدل‌ها و ارزیابی ۱۸

۴-۲ بهینه‌سازی پارامترها ۲۰

۴-۳ مقایسه مدلها ۲۰

۱- بررسی داده‌های خام – EDA

هدف اصلی تحلیل اکتشافی داده‌ها یا EDA، درک عمیق داده‌ها است. این فرآیند شامل خواندن داده‌ها، تلاش برای درک ویژگی‌هایی که بر داده‌ها تأثیر می‌گذارند، بررسی اندازه مجموعه داده و اطلاعات متعدد دیگری است که می‌توانند بعداً ما را در انجام مهندسی داده و انتخاب ویژگی بهینه هدایت کنند. این فرآیند ضروری است تا در بخش تحلیل دسته‌به نتایج بهتری دست یابیم.

اهداف اصلی این بخش

۱. خواندن داده‌ها با استفاده از متد info و describe.

2. مدیریت مقادیر گمشده.

۴. انجام آنالیز همبستگی برای یافتن مقادیری که بر نوع خرابی دستگاه تاثیر می‌گذارند.

در این گزارش سعی شده تا حد امکان تنها نتایج تفسیر و نمایش داده‌شوند و از آوردن توضیحات کد صرفنظر شده‌است.

۱-۱ خوانش و آشنایی اولیه با داده‌ها

دستور df.info به ما این امکان را می‌دهد که به‌صورت دقیق‌تری به مجموعه‌داده کنیم. در ادامه برخی ویژگی‌های این مجموعه‌داده که جلب توجه می‌کنند، آورده شده‌اند:

۱. این مجموعه‌داده شامل حدود ۱۰ هزار رکورد و ۶ ستون است که هدف، تعیین مقدار FailureType با استفاده از روش‌های طبقه‌بندی (Classification) می‌باشد.

۲. داده‌ها شامل اطلاعات عددی مانند دمای هوا(Air temp) ، دمای فرایند(Process temp) ، دور بر دقیقه (RPM)، گشتاور (Torque) و میزان ساییدگی ابزار (Tool wear) هستند.

۳. ویژگی‌ها (Features) همگی دارای مقادیر عددی هستند و متغیر هدف (Target) یک مقدار دسته‌ای (Categorical) است که نوع خرابی ماشین را مشخص می‌کند.

در ادامه نتایج این متد از جمله نوع داده‌ها (Data type) و مقدار مقادیر ناموجود در شکل زیر نمایش داده‌شده است:

```
0   Air Temp (°C)           9965 non-null   float64
1   Process Temp (°C)       9990 non-null   float64
2   Rotational Speed (RPM)  10000 non-null  float64
3   Torque (Nm)             10000 non-null  float64
4   Tool Wear (Seconds)     9993 non-null   float64
5   Failure Types           9991 non-null   object
```

شکل ۱-۱ نتایج با متد ()info

در این بخش از متد داخلی ()describe در کتابخانه پانداس استفاده می‌شود تا اطلاعات مورد نیاز جمع‌آوری شود.

۱- برای ستون‌های عددی:

اطلاعاتی مانند حداقل مقدار(min)، حداکثر مقدار(max)، انحراف معیار (std) و سایر آماره‌ها نمایش داده می‌شود.

۲- برای ستون‌های دسته‌ای:

تعداد مقادیر منحصر به فرد (Number of Unique Values) در هر ستون نشان داده می‌شود.

	Air Temp (°C)	Process Temp (°C)	Rotational Speed (RPM)	Torque (Nm)	Tool Wear (Seconds)
count	9965.000000	9990.000000	10000.000000	10000.000000	9993.000000
mean	28.516926	80.812186	1401.909988	46.998845	11393.143344
std	7.719340	15.548350	968.446183	26.747646	9023.336380
min	20.001366	60.001876	0.047731	0.015920	3.469877
25%	23.176455	68.090324	423.672240	18.091381	5023.027818
50%	26.212082	76.553203	1377.047835	54.983239	8995.172952
75%	29.377536	92.825894	2307.969925	67.258375	15024.825673
max	49.998008	119.971025	2999.953724	89.993221	35999.566519

شکل ۱-۲ نتایج با متد ()describe

همچنین برای یافتن اطلاعات بیشتر درباره ستون هدف یعنی Failure Types از متد ()value_counts استفاده شده تا مقدار موجود در هر کلاس از این ستون مشخص شود:

```
Failure Types
Power Failure                1999
Tool Wear Failure            1999
No Failure                   1998
Heat Dissipation Failure     1998
Overstrain                   1997
```

شکل ۱-۳ توزیع مقادیر در ستون با هدف

۱-۲ تحلیل و مدیریت مقادیر ناموجود

ابتدا تعداد مقادیر ناموجود و نسبت مقادیر ناموجود به کل مقادیر برای هر ستون را محاسبه می‌کنیم:

```
Columns with Missing Values:
                    Missing Values  Percentage (%)
Air Temp (°C)                   35           0.35
Process Temp (°C)               10           0.10
Tool Wear (Seconds)              7           0.07
Failure Types                    9           0.09

Total Missing Values: 61
Percentage of Total Missing Values: 0.10%
```

شکل ۱-۴ اطلاعات مقادیر ناموجود در دیتاست

همانطور که دیده می‌شود، تعداد مقادیر ناموجود در این دیتاست به نسبت بسیار کم می‌باشد.

از آنجا بسیاری از پیش‌پردازش‌ها و روش‌های یادگیری ماشین نسبت به وجود مقادیر ناموجود حساس بوده، نیاز از تا آنها را مدیریت کنیم. این کار در ۳ مرحله انجام می‌شود:

۱. برای **ستون‌های دسته‌ای (Categorical) یا متغیر هدف(Target)** ، سطرهای دارای مقادیر گمشده حذف می‌شوند زیرا این کار ایمن‌تر است. از طرفی تعداد این سطرها تنها ۹ عدد می‌باشد و اخلالی ایجاد نخواهد کرد.

۲. برای **ستون‌های عددی(Numerical)** ، مقادیر گمشده با میانه (Median) جایگزین می‌شوند تا مقادیر خارج از بازه تاثیری نداشته باشند.

۳. اطمینان از این‌که هیچ مقدار گمشده‌ای باقی نمانده است.

۳-۱ تحلیل همبستگی برای یافتن ویژگی‌های مهم – Correlation Analysis

برای شناسایی ویژگی‌های مهم‌تر، نیاز داریم که **همبستگی (Correlation)** بین هر ویژگی عددی و متغیر هدف که همان نوع خرابی (Failure Type) است را محاسبه کنیم. از آنجایی که متغیر هدف یک مقدار **دسته‌ای (Categorical)** بدون ترتیب مشخص (Ordinal) است، استفاده از روش معمول **همبستگی پیرسون Pearson Correlation** که معمولا انجام می‌شود، مناسب نیست و هر چند این روش جواب می‌دهد اما نتایج آن از نظر منطقی قابل تفسیر نیستند.

در عوض، از **آزمون ANOVA یا تحلیل واریانس Analysis of Variance** استفاده می‌کنیم. این آزمون بررسی می‌کند که آیا میانگین یک ویژگی عددی، در بین کلاس‌های مختلف متغیر هدف تفاوت معناداری دارد یا نه. در این آزمون دو مقدار مهم محاسبه می‌شود:

- **مقدار F (F-value):** نسبت واریانس بین گروهی به واریانس درون‌گروهی است؛ هرچه این مقدار بزرگ‌تر باشد، به این معناست که تفاوت میانگین‌ها بین کلاس‌ها بیشتر است.
- **مقدار p (p-value):** احتمال این است که تفاوت مشاهده‌شده در میانگین‌ها به‌طور تصادفی رخ داده باشد . p-valueپایین‌تر از ۰,۰۵ معمولاً نشان‌دهنده‌ی معنادار بودن تفاوت است.

این بخش در ۴ مرحله انجام می‌شود:

۱. محاسبه مقادیر F و p برایANOVA برای این کار، ابتدا باید متغیر هدف را به مقادیر عددی تبدیل کنیم . این کار با label encoder انجام شده که مقادیر دسته ای را به عددی تبدیل می‌کند.

۲. مصورسازی اهمیت ویژگی‌ها بر اساس مقدارF .

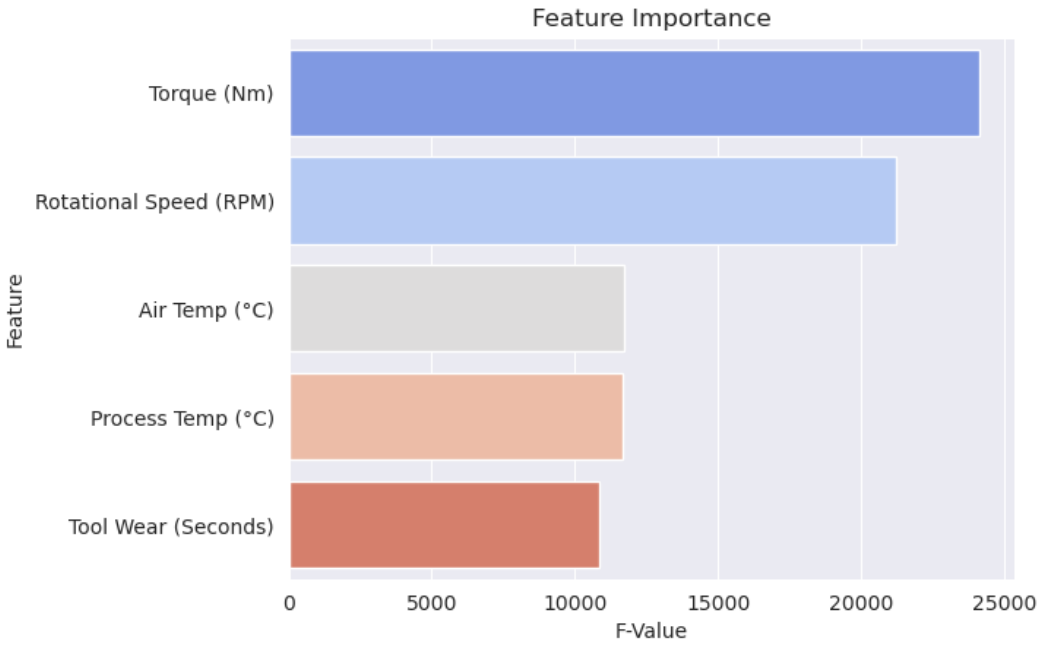
۳. نمایش سه ویژگی با بالاترین ارتباط با متغیر هدف، با استفاده از نمودارbox plot و هیستوگرام

نتایج تست ANOVA بصورت زیر می‌باشد:

	Feature	F-Value	p-Value
3	Torque (Nm)	24114.558715	0.0
2	Rotational Speed (RPM)	21233.746448	0.0
0	Air Temp (°C)	11721.230565	0.0
1	Process Temp (°C)	11676.234816	0.0
4	Tool Wear (Seconds)	10851.597293	0.0

شکل ۱-۵ نتایج تست ANOVA

همانطور که مشاهده می‌شود تمامی مقادیر p نزدیک به صفر بوده که نشان از مرتبط بودن ویژگی‌ها با ستون هدف دارد. مقایسه اهمیت ویژگی‌ها بر اساس F-Value انجام می‌شود:

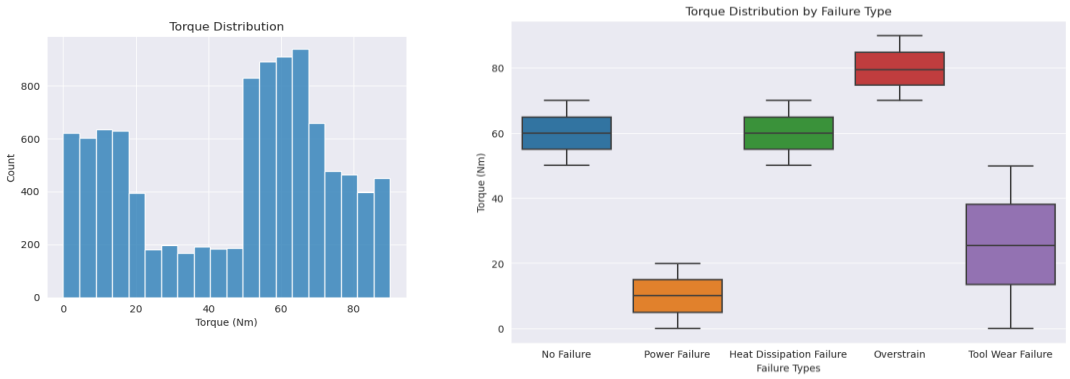


شکل ۱-۶ اهمیت ویژگی‌ها

همانطور که مشاهده می‌شود، میزان گشتاور وارد شده به دستگاه و همچنین سرعت چرخش و دما (هم دمای پروسه و هم دمای هوا) از ویژگی‌های مهم می‌باشد.

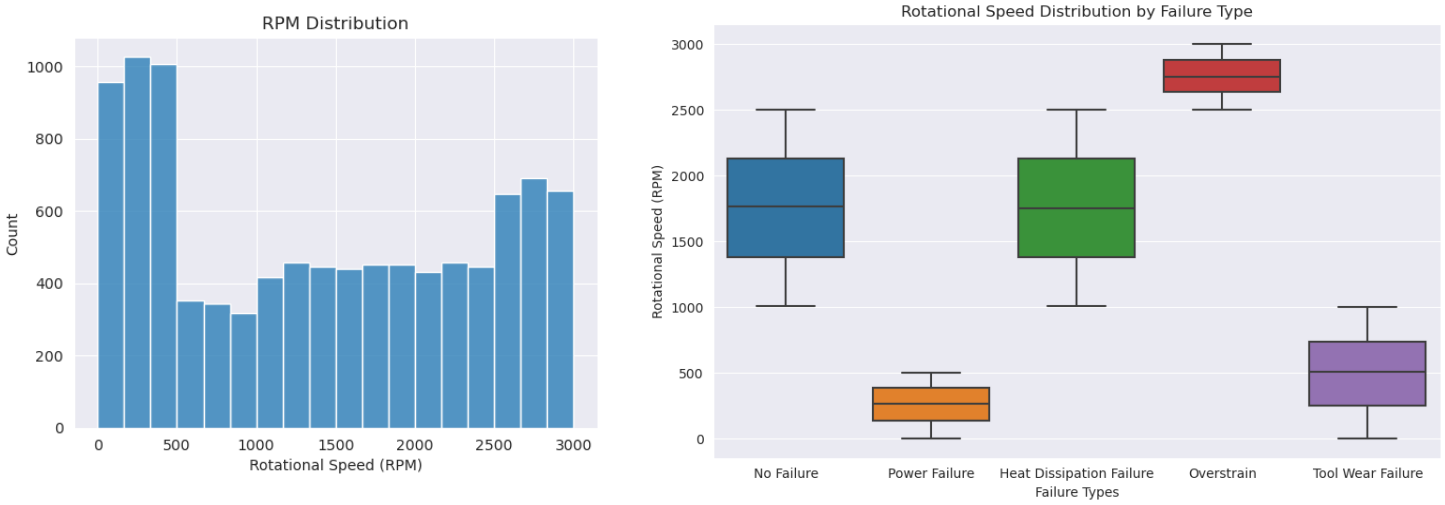
در ادامه نمودارهای توزیع سه ویژگی Torque, RPM, Process Temp آورده شده و بر روی آنها بحث می‌شود.

- Torque



شکل ۱-۷ نمودار Box plot و Histogram برای Torque

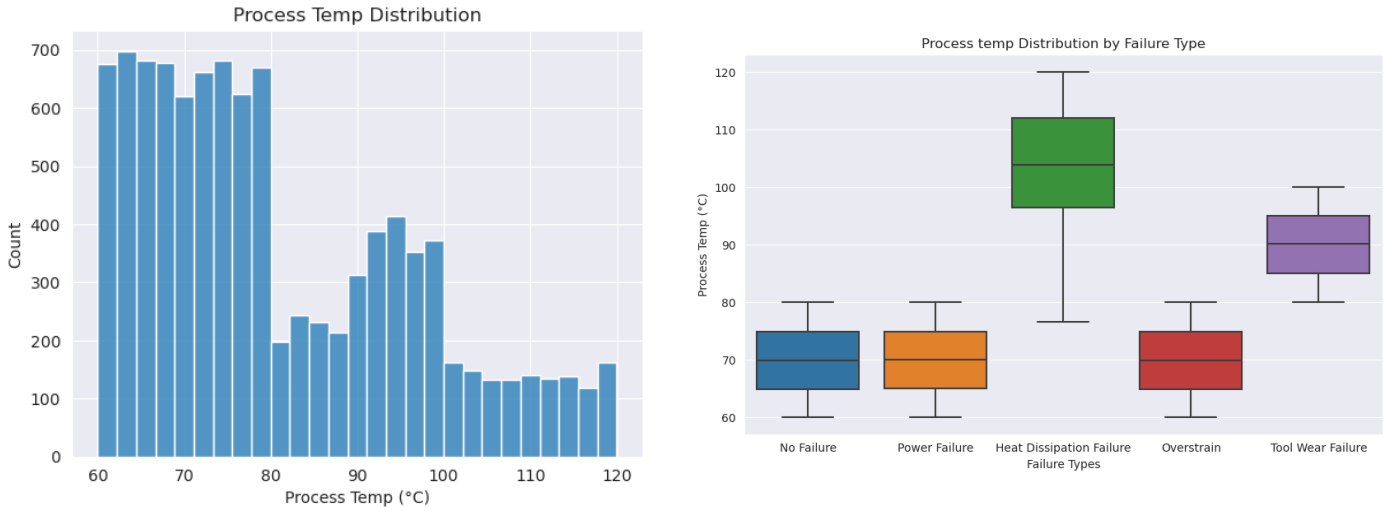
- Rotational Speed



شکل ۱-۸ نمودار Box plot و Histogram برای RPM

همانطور که مشاهده می‌شود، خرابی نوع Overstrain که ناشی از فشار زیاد به دستگاه بوده در سرعت های RPM بالا رخ داده که این موضوع منطقی می‌باشد.

- Process Temp



شکل ۱-۹ نمودار Box plot و Histogram برای Process Temp

همانطور که مشاهده می‌شود خرابی نوع Heat Dissipiation در دماهای بالا رخ می‌دهد.

۲- پیش‌پردازش داده‌ها – Data Preprocessing

این بخش شامل پاک‌سازی داده‌ها است، از جمله:

۱. مدیریت مقادیر گمشده — (Missing data) **قبلاً انجام شده است.**

۲. شناسایی و حذف نقاط پرت (Outliers) با استفاده از روشIQR برای دو ویژگی برتر که بیشترین همبستگی را با متغیر هدف دارند یعنی **RPM** و **Torque**.

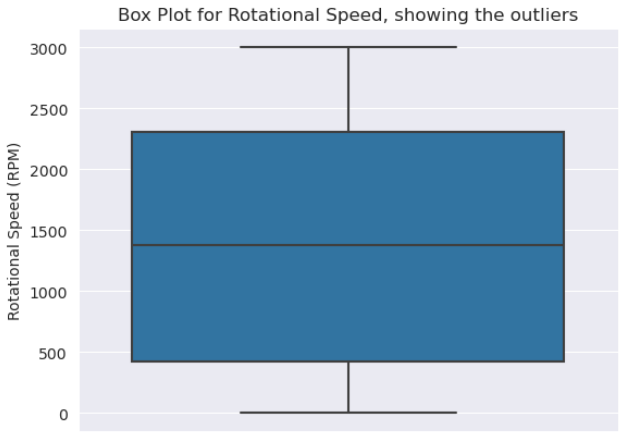
۳. نرمال‌سازی (Normalize) و استانداردسازی (Standardize) داده‌ها در صورت نیاز

۲-۱ حذف مقادیر پرت

در این مرحله ابتدا تعداد مقادیر پرت توسط روش IQR شناسایی شده و سپس این مقادیر حذف می‌گردد.

- برای Rotational Speed

```
Q1: 423.31567388288374
Q3: 2307.6573904092356
IQR: 1884.3417165263518
Lower Bound: -2403.196900906644
Upper Bound: 5134.169965198764
Number of Outliers for rotational Speed: 0
```

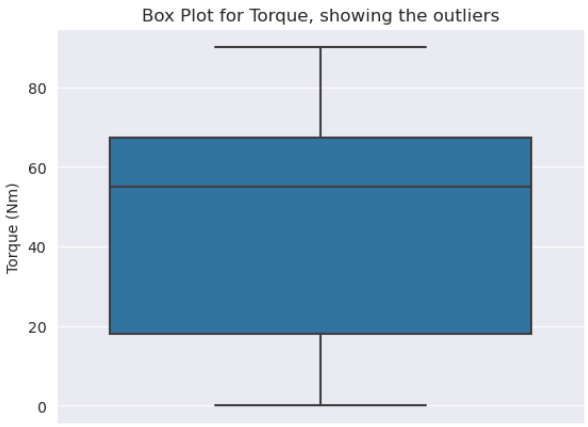


شکل ۲-۱ مقادیر پرت برای RPM

همانطور که هم از نمودار و هم از تحلیل IQR مشخص است، این ستون دارای مقدار خارج از بازه نمی‌باشد.

- برای Torque

```
Q1: 18.090987798433975
Q3: 67.25371840091196
IQR: 49.16273060247799
Lower Bound: -55.65310810528301
Upper Bound: 140.99781430462895
Number of Outliers for rotational Speed: 0
```



شکل ۲-۲ مقادیر پرت برای Torque

که این ستون نیز عاری از مقادیر خارج از بازه بوده و تحلیل مقادیر پرت برای این دیتاست بدون نتیجه می‌باشد.

۲-۲ فرآیندهای Normalize و Standardize

نرمال‌سازی(Normalization) ، که با نام **مقیاس‌بندی مین-مکس (Min-Max Scaling)** نیز شناخته می‌شود، یک تکنیک مقیاس‌بندی ویژگی‌هاست که داده‌ها را به یک بازه‌ی ثابت، معمولاً بین **۰ و ۱** تبدیل می‌کند. این روش شکل توزیع اصلی داده‌ها را حفظ می‌کند. در نرمال‌سازی، هر ویژگی به‌صورت جداگانه مقیاس‌بندی می‌شود؛ به این صورت که **کمترین مقدار** از هر مقدار کم شده و سپس حاصل، بر **دامنه (بیشینه منهای کمینه)** تقسیم می‌شود. فرمول نرمال‌سازی به صورت زیر است:

$$X_{Normalized} = \frac{X - X_{\min}}{X_{\max} - X}$$

استانداردسازی(Standardization) ، که با نام **نرمال‌سازی-Z نمره (Z-score Normalization)** نیز شناخته می‌شود، یکی دیگر از روش‌های مهم مقیاس‌بندی ویژگی‌هاست که داده‌ها را به‌گونه‌ای تبدیل می‌کند که **میانگین برابر با صفر** و **انحراف معیار برابر با یک** داشته باشند. این روش به‌ویژه زمانی مفید است که ویژگی‌ها دارای توزیع نرمال (گاوسی) باشند. در این روش، هر ویژگی با **کم‌کردن میانگین** و **تقسیم بر انحراف معیار** مقیاس‌بندی می‌شود.

فرمول استانداردسازی به صورت زیر است:

$$X_{standardized} = \frac{X - \mu}{\sigma}$$

حال سوال اصلی این است که آیا در این دیتاست نیاز به این فرآیند ها می‌باشد یا خیر؟

پاسخ مثبت است، در ادامه دلایلی برای این تصمیم آورده شده‌اند:

ویژگی‌های ما مقیاس‌های متفاوتی دارند؛ به‌عنوان مثال، مقدار Air Temp در بازه‌ی ۲۰ تا ۴۰ قرار دارد، در حالی که RPM در محدوده‌ی هزاران است. این تفاوت مقیاس در بسیاری از الگوریتم‌های یادگیری ماشین می‌تواند مشکل‌ساز شود.

الگوریتم‌های مبتنی بر فاصله مانند **KNN** به مقیاس داده‌ها حساس هستند و این نوع تکنیک‌های مقیاس‌بندی به عملکرد بهتر آن‌ها کمک می‌کنند.

الگوریتم‌های مبتنی بر درخت مانند **Random Forest** نسبت به مقیاس ویژگی‌ها **غیرحساس** هستند و نیازی به مقیاس‌بندی ندارند.

بنابراین، در این مرحله از **استانداردسازی (Standardization)** برای ویژگی‌ها استفاده می‌کنیم.

شایان ذکر است که به‌منظور جلوگیری از **نشت داده (Data Leakage)** ، ابتدا باید داده‌ها به **داده‌های آموزش و آزمون (Train/Test Split)** تقسیم شوند و همچنین ستون جدید (ویژگی مشتق‌شده) ایجاد و **کدگذاری (Encoding)** شود، سپس عملیات مقیاس‌بندی انجام گیرد. در نتیجه، برخی از تمرین‌های قسمت بعد در این مرحله انجام می‌شود.

پس از انجام فرآیند استاندارسازی، ستون‌های ویژگی به شکل زیر در خواهند آمد:

```
array([[ 1.39634517,  0.73469686,  0.2994436 ,  0.38641119,  0.02130031],
       [-0.02880073, -0.06108035,  0.08978278,  0.76574629, -0.67995244],
       [-0.94805429, -0.85401032, -0.17651046,  0.7163321 , -0.58799456],
       ...,
       [-0.08074734, -0.30470612,  0.20936118,  0.84117711, -0.61977677],
       [ 2.63295509,  0.87527835,  0.82752219,  0.41416856, -0.86650164],
       [ 1.02723938,  2.0759435 ,  0.54032942,  0.28005662, -0.43976512]])
```

شکل ۲-۳ نمونه ستون‌های ویژگی پس از استاندارسازی

همچنین ستون جدیدی به عنوان Broken ایجاد شده که خراب بودن یا نبودن ماشین را نمایش می‌دهد که برای دسته‌بندی دوگانه نیاز می‌باشد.

برای دسته‌بندی چندگانه نیز ستون Types of Failure به مقادیر عددی تبدیل شده‌اند:

```
0 → Heat Dissipation Failure
1 → No Failure
2 → Overstrain
3 → Power Failure
4 → Tool Wear Failure
```

شکل ۲-۴ مقادیر ستون Types of Failure پس از Endoding

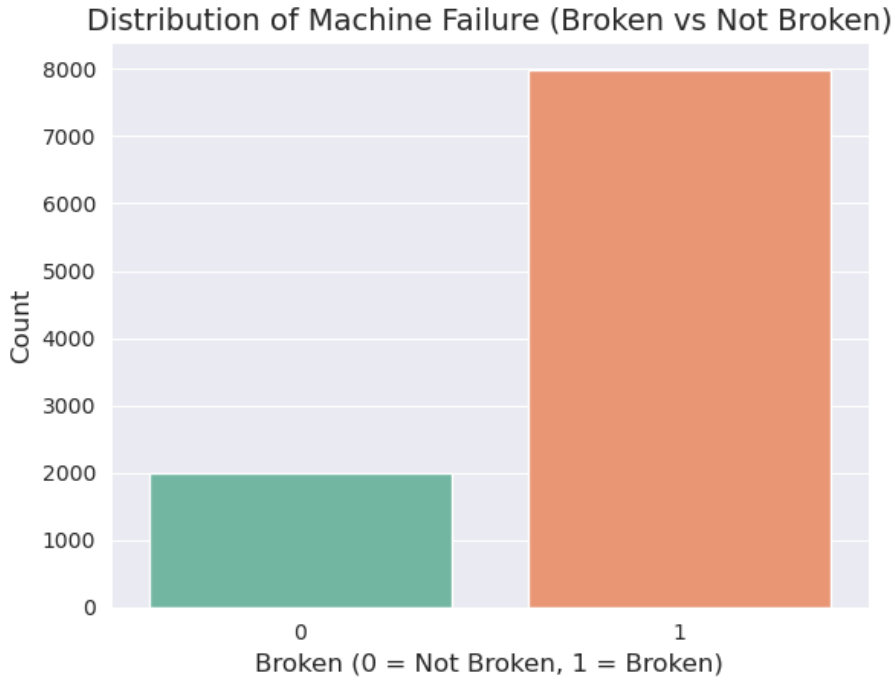
لازم به ذکر است که در این مرحله داده به قسمت های آموزش و تست تبدیل شده‌است.

۳- دسته‌بندی دوگانه

هدف این قسمت، بررسی خراب بودن یا نبودن دستگاه است که یک دسته‌بندی دوگانه Binary Classification می‌باشد.

۳-۱ بررسی و مدیریت عدم توازن داده‌ها – Unbalanced Data Analysis

برای این امر، توزیع داده‌ها در ستون Broken نمایش داده می‌شود:



شکل ۳-۱ توزیع داده‌های خراب و سالم

همان‌طور که مشاهده می‌شود، داده‌ها به‌شدت **نامتوازن (Unbalanced)** و **دارای انحراف (Skewed)** هستند؛ به‌طوری که تعداد نمونه‌های مربوط به حالت **"شکسته (Broken) "** تقریباً **۴ برابر** بیشتر از حالت **سالم** است. این عدم توازن می‌تواند منجر به مشکلاتی مانند موارد زیر شود:

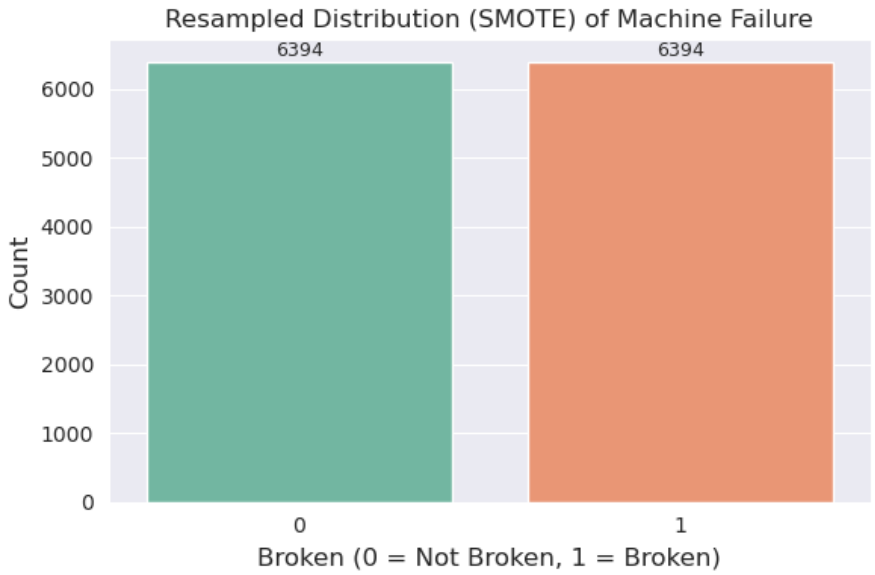
۱. **پیش‌بینی‌های دارای سوگیری :**مدل ممکن است برای به‌حداکثر رساندن دقت، تقریباً همه نمونه‌ها را به‌صورت "سالم" پیش‌بینی کند.

۲. **دقت گمراه‌کننده :**دقت بالایی مانند ٪۹۵ ممکن است تنها به این دلیل باشد که مدل در حال پیش‌بینی کلاس اکثریت است، در حالی که بیشتر شکست‌های واقعی را از دست می‌دهد.

برای مقابله با این مشکل، از روشی به نام **SMOTE** استفاده می‌شود.

SMOTE مخفف **Synthetic Minority Over-sampling Technique** است؛ یک روش افزایش نمونه (Oversampling) هوشمندانه که با ایجاد نمونه‌های مصنوعی (Synthetic) از کلاس اقلیت، توازن بین کلاس‌ها را برقرار می‌کند. برخلاف تکرار ساده‌ی نمونه‌های اقلیت، SMOTEبا در نظر گرفتن همسایگی نزدیک هر نمونه اقلیت، داده‌های جدیدی در فضای ویژگی‌ها تولید می‌کند که مشابه نمونه‌های واقعی اما نه تکراری هستند.

با این کار، مدل یادگیری ماشین فرصت بیشتری برای یادگیری الگوهای مربوط به کلاس اقلیت خواهد داشت و تعادل بهتری بین دقت (Accuracy) و یادآوری (Recall) ایجاد می‌شود.



شکل ۳-۱ توزیع داده‌های خراب یا سالم پس از اعمال روش SMOTE

۳-۲ آموزش مدل‌ها و ارزیابی

مدل‌های آموزش داده‌شده به همراه پارامترهایشان به شرح زیر می‌باشند:

1- Logistics Regression – Max Iteration : 1000

2- KNN – N_neighbours : 30

3- SVM – Kernel: Linear

4- SVM – Kernel: rbf

پس از آموزش مدل‌ها، معیارهای زیر برای ارزیابی برای هر مدل ضبط می‌گردند:

1- Accuracy

2- Precision

3- Recall

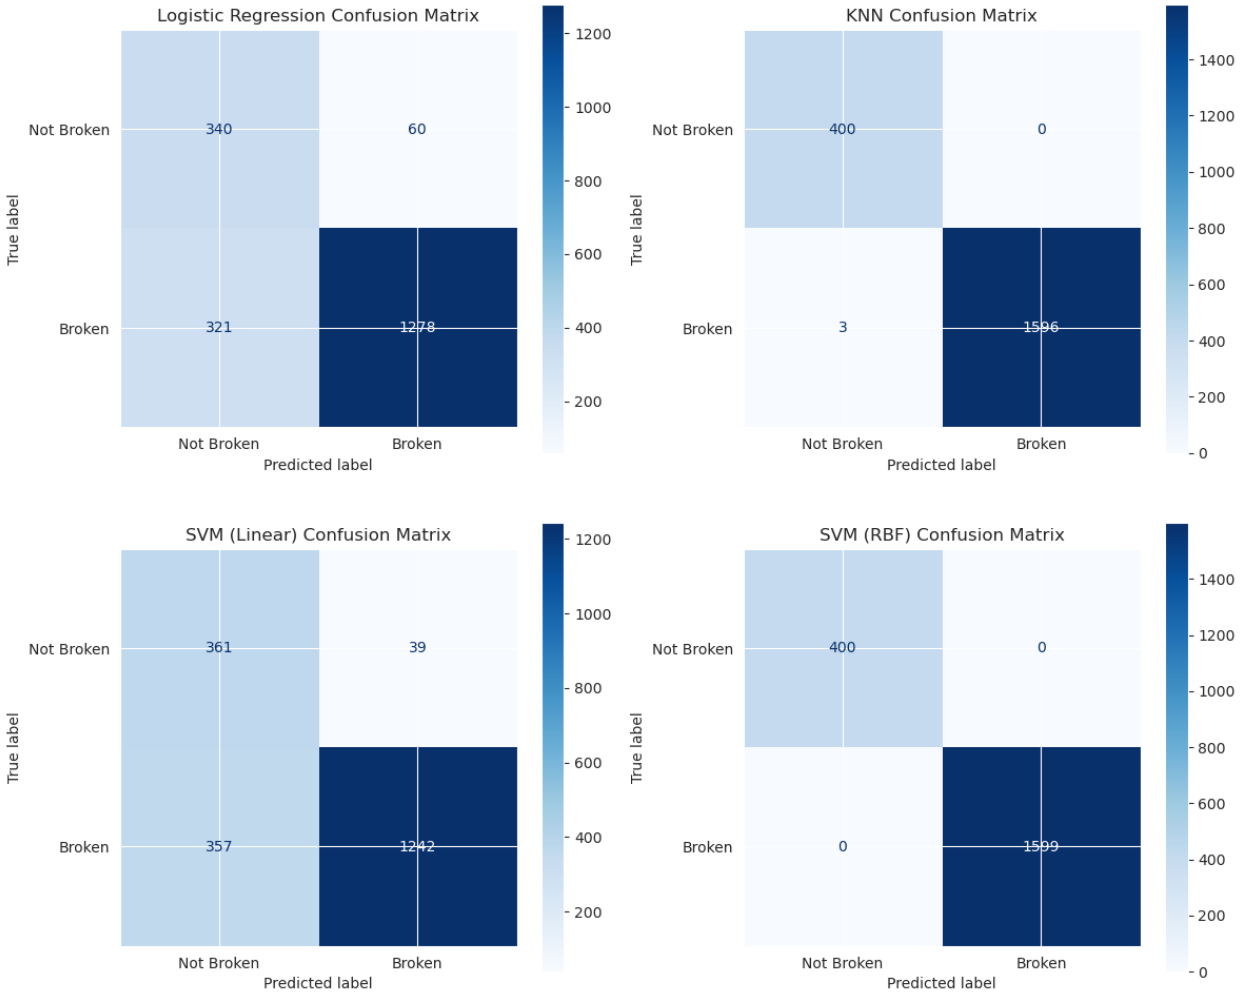
4- F1-Score

نتایج به شرح زیر می‌باشد:

	Model	Accuracy	Precision	Recall	F1 Score
3	SVM (RBF)	1.000000	1.000000	1.000000	1.000000
1	KNN	0.998499	1.000000	0.998124	0.999061
0	Logistic Regression	0.809405	0.955157	0.799250	0.870276
2	SVM (Linear)	0.801901	0.969555	0.776735	0.862500

شکل ۳-۲ نتایج ارزیابی مدل‌های دسته‌بندی دوگانه

همچنین ماتریس آشفتگی این مدل‌ها به شرح زیر می‌باشد:



شکل ۳-۴ ماتریس‌های آشفتگی برای مدل‌های دسته‌بندی دوگانه

۳-۴ بهینه‌سازی پارامترها – Fine Tuning Hyperpatameters

با روش Grid Search CV پارامترهای مختلفی برای هر مدل تست شده و بهترین آنها انتخاب می‌شود. بهترین پارامترها برای مدل‌های مختلف به شرح زیر می‌باشند:

```
{'Logistic Regression': {'C': 0.01, 'penalty': 'l2'},
 'KNN': {'n_neighbors': 3},
 'SVM (Linear)': {'C': 0.1, 'tol': 0.0001},
 'SVM (RBF)': {'C': 10, 'gamma': 'scale'}})
```

شکل ۳-۵ پارامترهای بهینه مدل‌های دسته‌بندی دوگانه

	Model	Accuracy	Precision	Recall	F1 Score
1	KNN	1.000000	1.000000	1.000000	1.000000
3	SVM (RBF)	1.000000	1.000000	1.000000	1.000000
0	Logistic Regression	0.802401	0.968847	0.777986	0.862990
2	SVM (Linear)	0.800900	0.972463	0.772983	0.861324

شکل ۳-۶ نتایج ارزیابی مدل‌های دسته‌بندی دوگانه پس از بهینه‌سازی پارامترها

۳-۵ ارزیابی و مقایسه مدل‌ها

همانطور که مشخص است مدل ماشین بردار پشتیبان با هسته غیرخطی بهترین عملکرد را دارا می‌باشد.

مدل ماشین بردار پشتیبان با هسته خطی نیز بدترین عملکرد را دارا می‌باشد.

همچنین لازم به ذکر است که در صورت بهینه‌سازی پارامترها، مدل KNN می‌تواند بسیار خوب عمل کند.

۴- دسته‌بندی چندگانه

۴-۱ آموزش مدل‌ها و ارزیابی

مدل‌های آموزش داده‌شده به همراه پارامترهایشان به شرح زیر می‌باشند:

1- KNN – N_neighbours : 50

2- SVM – one vs rest – C : 0.1 , kernel = linear

3- SVM – one vs others – C : 0.1 , Kernel = linear

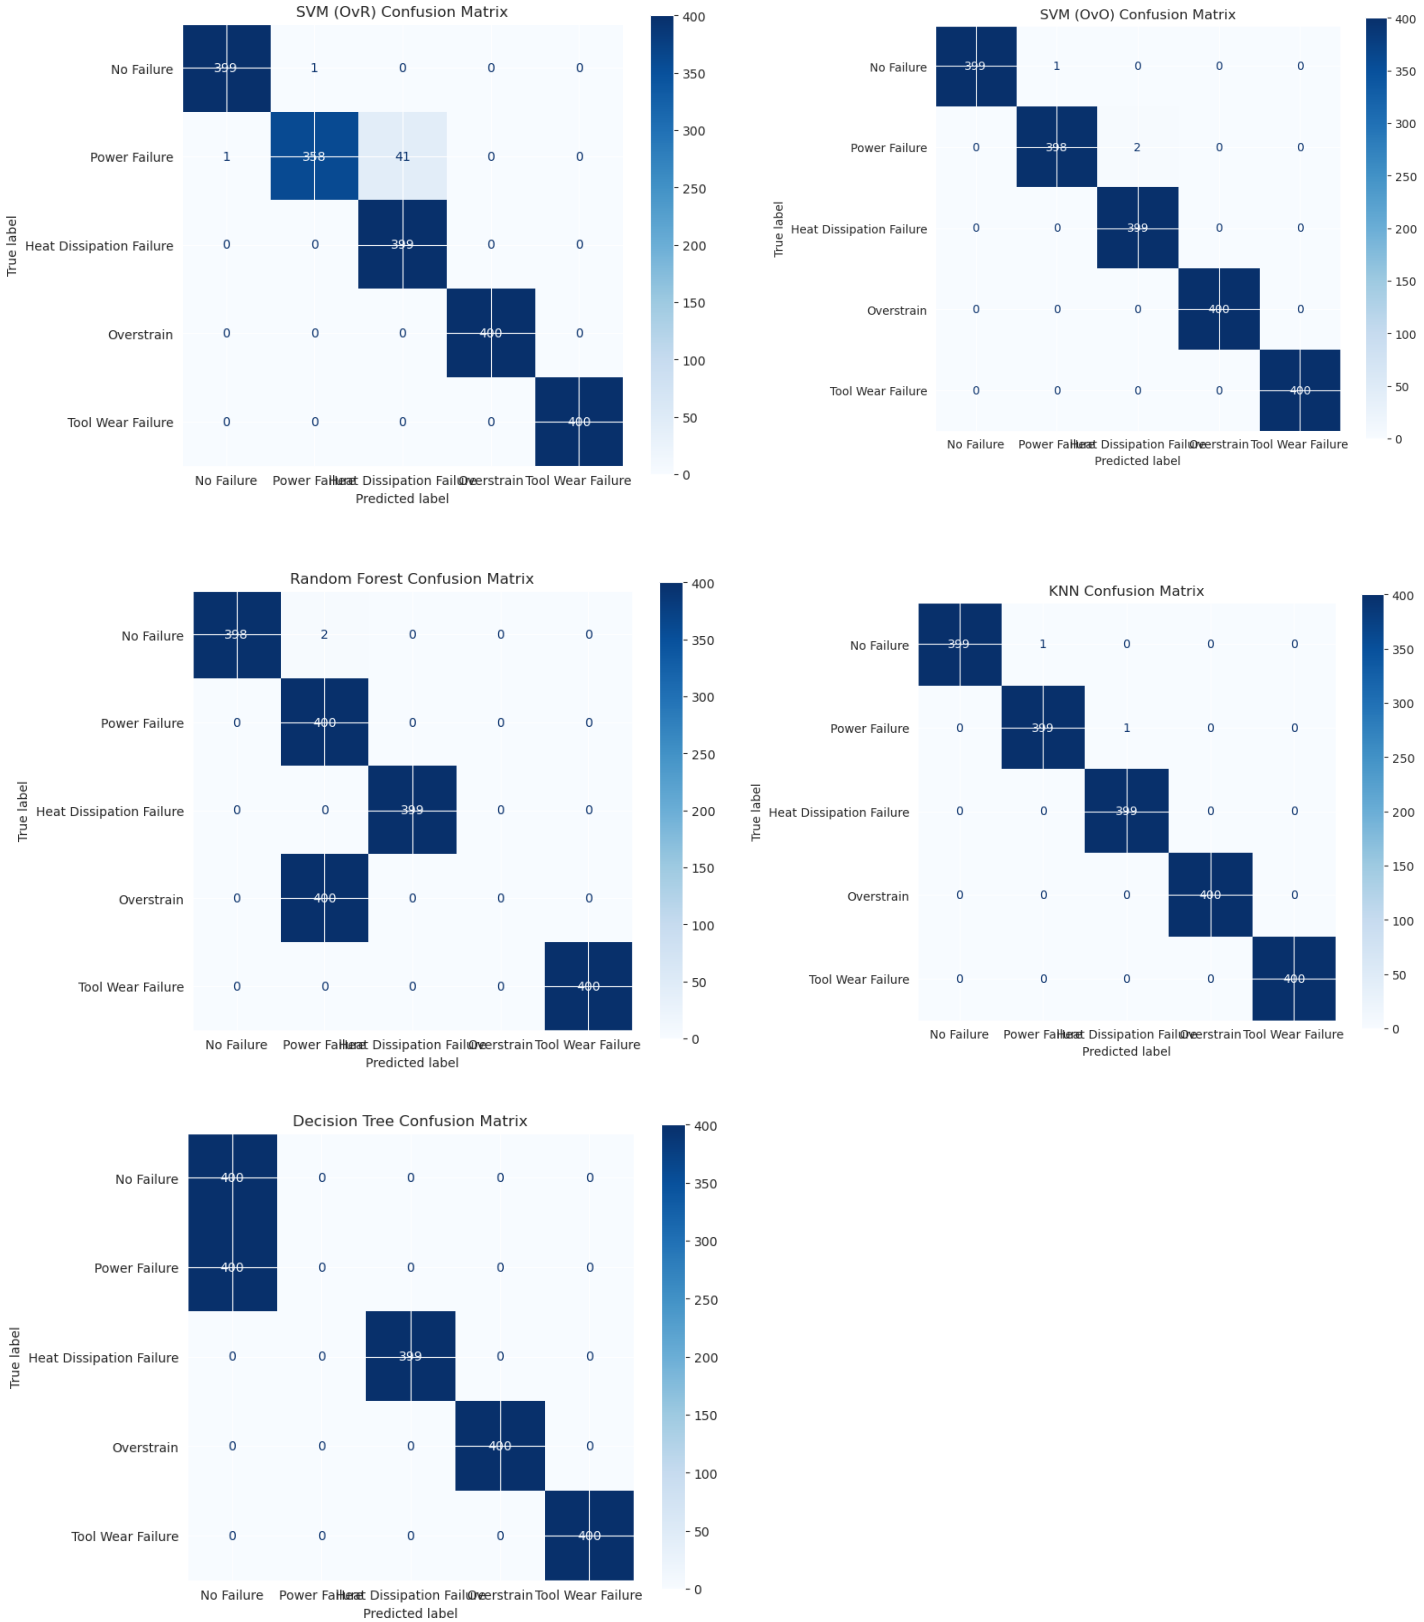
4- Decision Tree – max depth = 2

5- Random Forest: no of estimators: 2 , max depth = 2

نتایج آموزش این مدل‌ها به شرح زیر می‌باشد:

	Model	Accuracy	Precision (macro)	Recall (macro)	F1 Score (macro)
0	KNN	0.998999	0.999000	0.9990	0.998999
3	SVM (OvO)	0.998499	0.998501	0.9985	0.998499
4	SVM (OvR)	0.978489	0.980307	0.9785	0.978396
1	Decision Tree	0.799900	0.700000	0.8000	0.733333
2	Random Forest	0.798899	0.699751	0.7990	0.732610

شکل ۴-۱ نتایج ارزیابی مدل‌های دسته‌بندی چندگانه



شکل ۴-۲ ماتریس‌های آشفتگی برای مدل‌های دسته‌بندی چندگانه

۲-۴ بهینه‌سازی پارامترها

پارامترهای بهینه برای مدل‌های مختلف به شرح زیر می‌باشد:

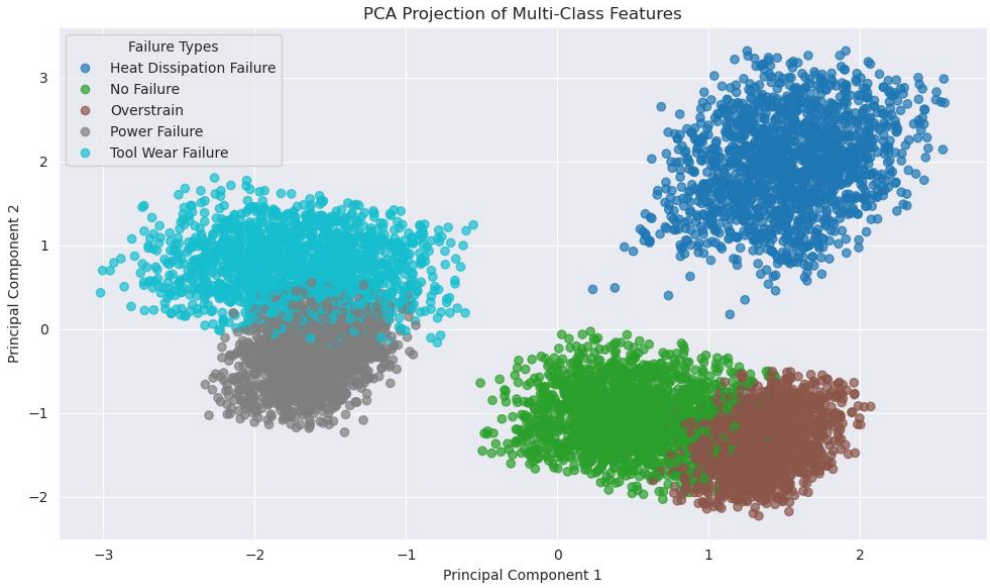
- KNN: `'n_neighbors': 3`
- Decision Tree: `'max_depth': 5, 'min_samples_split': 2`
- Random Forest: `'max_depth': 5, 'n_estimators': 50`
- SVM (OvO): `'estimator__C': 10, 'estimator__gamma': 0.1`
- SVM (OvR): `'estimator__C': 10, 'estimator__gamma': 'scale'`

همچنین نتایج مدل‌ها با پارامترهای بهینه‌شده به گونه‌ای است که همه مدل ها عملکرد کامل (F1 Score = 1) را دارا می‌باشند.

۳-۴ مقایسه مدل‌ها

همانطور که مشاهده شد دیتاست به نسبت ساده بوده و مدل‌های بهینه شده توانایی تشخیص تمامی کلاس‌ها را دارند.

برای بررسی بیشتر از روش PCA – Principal Component Analysis استفاده شده تا با Feature Extraction دو feature اصلی یافت شده تا ساده یا سخت بودن دیتاست بررسی شود:



شکل ۴-۳ تشخیص کلاس‌های مختلف با روش PCA

همانطور که مشخص است تنها با دو ویژگی، تمامی کلاس‌ها قابل تفکیک می‌باشند.

در بین روش‌های موجود نیز KNN از روش‌های دیگر بهتر می‌باشد.