دانشکده مهندسی مکانیک

پردیس دانشکده‌های فنی

دانشگاه تهران

هوش مصنوعی – نیمسال دوم ۴-۱۴۰۳

تمرین چهارم

(شبکه‌های عصبی)

نگارش:

علی خیری

۸۱۰۶۰۳۰۷۱

استاد درس:

دکتر شریعت‌پناهی

بهار ۱۴۰۴

۱- دادگان تشخیص فعالیت انسانی – UCI HAR

دیتاست **UCI HAR (Human Activity Recognition using Smartphones)** یکی از دیتاست‌های پرکاربرد در حوزه‌ی یادگیری ماشین و یادگیری عمیق برای **تشخیص فعالیت‌های انسانی** است. این مجموعه داده توسط سنسورهای شتاب‌سنج و ژیروسکوپ نصب‌شده روی گوشی‌های هوشمند جمع‌آوری شده و شامل داده‌های مربوط به فعالیت‌هایی مانند راه‌رفتن، نشستن، بالا رفتن از پله و غیره است.

ساختار پوشه‌ها و فایل‌های این دیتاست به‌صورت زیر سازمان‌دهی شده است:

- پوشه‌ی اصلی شامل فایل‌هایی مانند README.txt و features.txt است که توضیحاتی درباره‌ی داده‌ها و ویژگی‌ها ارائه می‌دهند.
- دو پوشه‌ی کلیدی به نام‌های /train و /test داده‌ها را به مجموعه‌های آموزشی و آزمایشی تقسیم می‌کند که داخل این پوشه‌ها شامل داده‌های ویژگی استخراج‌شده از سیگنال‌ها و برچسب فعالیت برای هر نمونه وجود دارند.

۱-۱ روش‌های مختلف نرمال‌سازی داده

فرآیندهای MinMaxScaling و استانداردسازی به عنوان دو روش اصلی نرمال‌سازی داده بشمار می‌روند:

نرمالسازی یا Normalization، که با نام مقیاس بندی مین-مکسMin-Max-Scaling نیز شناخته می‌شود، یک تکنیک مقیاس‌بندی ویژگی‌هاست که داده‌ها را به یک بازه‌ی ثابت، معمولاً بین ۰ و ۱ تبدیل می‌کند. این روش شکل توزیع اصلی داده‌ها را حفظ می‌کند. در نرمالسازی، هر ویژگی به‌صورت جداگانه مقیاس‌بندی می‌شود؛

به این صورت که کمترین مقدار از هر مقدار کم شده و سپس حاصل، بر دامنه تقسیم میشود. فرمول نرمالسازی به صورت زیر است :

$$X_{Normalized} = \frac{X - X_{\min}}{X_{\max} - X}$$

استانداردسازی یا Standardization، که با نام نرمالسازی- Z نیز شناخته می‌شود، یکی دیگر از روش‌های مهم مقیاس‌بندی ویژگی‌هاست که داده‌ها را به‌گونه‌ای تبدیل می‌کند که میانگین برابر با صفر و انحراف معیار برابر با یک داشته باشند. این روش به‌ویژه زمانی مفید است که ویژگی‌ها دارای توزیع گاوسی باشند. در این روش، هر ویژگی با کم‌کردن میانگین و تقسیم بر انحراف معیار مقیاس‌بندی می‌شود.

در این پروژه از نرمال‌سازی استفاده می‌شود.

۱-۲ آماده‌سازی داده‌ها

اولین وظیفه، بارگذاری و پیش‌پردازش داده‌هاست تا شکل و فرمت آن برای استفاده در شبکه‌ی عصبی MLP مناسب باشد. مراحل مورد نیاز به شرح زیر است:

۱. **بارگذاری داده‌ها** :ابتدا داده‌های آموزش و آزمون از فایل‌های موجود، داخل آرایه‌ها ذخیره می‌شوند.

۲. **تقسیم داده‌ها** :پس از داشتن داده‌های آموزش و آزمون، داده‌ی آموزش را به دو بخش آموزش و اعتبارسنجی (Train- Validation- test) تقسیم می‌کنیم. داده‌های آموزش و اعتبارسنجی در فرآیند آموزش به کار می‌روند و داده‌ی آزمون برای ارزیابی نهایی استفاده خواهد شد.

۳. **مقیاس‌بندی داده‌ها** :همانطور که گفته شد، از مقیاس‌بندی Min-Max-Scaling استفاده می‌شود.

```
X_train shape: (6249, 561)
y_train shape: (6249,)
X_train shape: (1103, 561)
y_train shape: (1103,)
X_test shape: (2947, 561)
y_test shape: (2947,)
Number of features: 561
Activities: {1: 'WALKING', 2: 'WALKING_UPSTAIRS', 3: 'WALKING_DOWNSTAIRS', 4: 'SITTING', 5: 'STANDING', 6: 'LAYING'}
```

شکل ۱-۱ تعداد داده‌ها پس از تقسیم‌بندی (Validation در سطرهای سوم و چهارم به اشتباه Train نوشته شده‌است)

۱-۳ طراحی شبکه MLP

در این بخش به اجزای شبکه‌ی عصبی MLP طراحی‌شده و دلایل انتخاب آن‌ها می‌پردازیم:

- **ساختار کلی مدل** :ورودی مدل شامل ۵۶۱ ویژگی عددی است. پس از آن، دو لایه‌ی پنهان با به‌ترتیب ۲۵۶ و ۱۲۸ نورون قرار دارند. برای کاهش **بیش‌برازش(Overfitting)** ، پس از هر لایه از تکنیک **Dropout** با نرخ ۰,۳ استفاده شده است. در پایان، یک لایه‌ی خروجی با ۶ نورون قرار دارد که هر نورون نماینده‌ی یکی از فعالیت‌های انسانی است.

- **توابع فعال‌سازی** :در لایه‌های پنهان از تابع ReLU استفاده شده است که رایج‌ترین تابع فعال‌سازی در شبکه‌های عمیق محسوب می‌شود ReLU .با افزودن خاصیت غیرخطی، امکان یادگیری الگوهای پیچیده را فراهم می‌کند. در لایه‌ی خروجی، از تابع softmax استفاده شده که برای مسائل **طبقه‌بندی چندکلاسه**

ایده‌آل است؛ زیرا خروجی شبکه را به یک توزیع احتمالی بین ۰ تا ۱ نگاشت می‌کند، به‌طوری‌که مجموع خروجی‌ها برابر با ۱ خواهد بود.

- **تابع هزینه (Loss Function)**: از sparse_categorical_crossentropy استفاده شده است، چرا که برچسب‌های هدف (y) به صورت **عدد صحیح** کدگذاری شده‌اند (یعنی ۱ تا ۶) و نیازی به One-hot-encoding ندارد.

برای داشتن مقایسه عادلانه بین مدل‌ها، پارامترهای زیر برای آموزش تمامی مدل‌های این تمرین مورد استفاده قرار گرفته:

جدول ۰-۱ هایپرپارامترهای استفاده‌شده در آموزش مدل‌ها

Batch Size	32
Optimizer	Adam
No of Epoch	20
Learning Rate	0.001
Metric	Accuracy

پس از آموزش مدل، نمودارهای Accuracy and Loss بصورت زیر می‌باشد:



شکل ۲-۱ نمودارهای خطا و دقت برای مدل MLP

در ادامه برای ارزیابی مدل‌ها، معیارهای Precision, Recall, F1 Score, Confusion Matrix نمایش داده‌شده اند:

```
Test Loss: 0.1184
Test Accuracy: 0.9610
                    precision    recall  f1-score   support

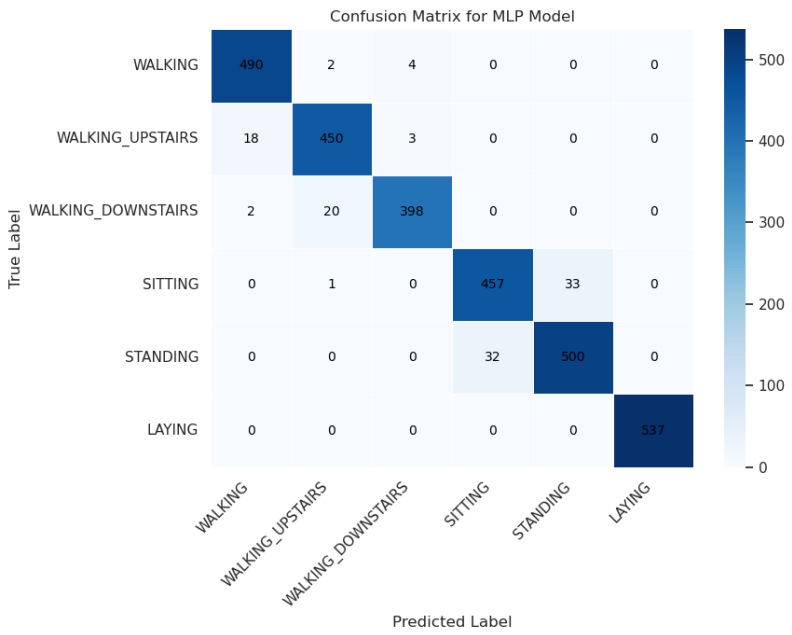
           WALKING       0.96      0.99      0.97       496
  WALKING_UPSTAIRS       0.95      0.96      0.95       471
WALKING_DOWNSTAIRS       0.98      0.95      0.96       420
           SITTING       0.93      0.93      0.93       491
          STANDING       0.94      0.94      0.94       532
            LAYING       1.00      1.00      1.00       537

          accuracy                           0.96      2947
         macro avg       0.96      0.96      0.96      2947
      weighted avg       0.96      0.96      0.96      2947


Overall Test Accuracy (from sklearn): 0.9610
Weighted Precision: 0.9611
Weighted Recall: 0.9610
Weighted F1-Score: 0.9610
```

شکل ۳-۱ دقت مدل MLP روی داده‌های Test

همانطور که مشخص است، مدل به دقت ۹۶٪ روی داده‌هایی که از پیش ندیده دست می‌یابد.



شکل ۱-۴ ماتریس آشفتگی برای مدل MLP

۴-۱ طراحی شبکه CNN

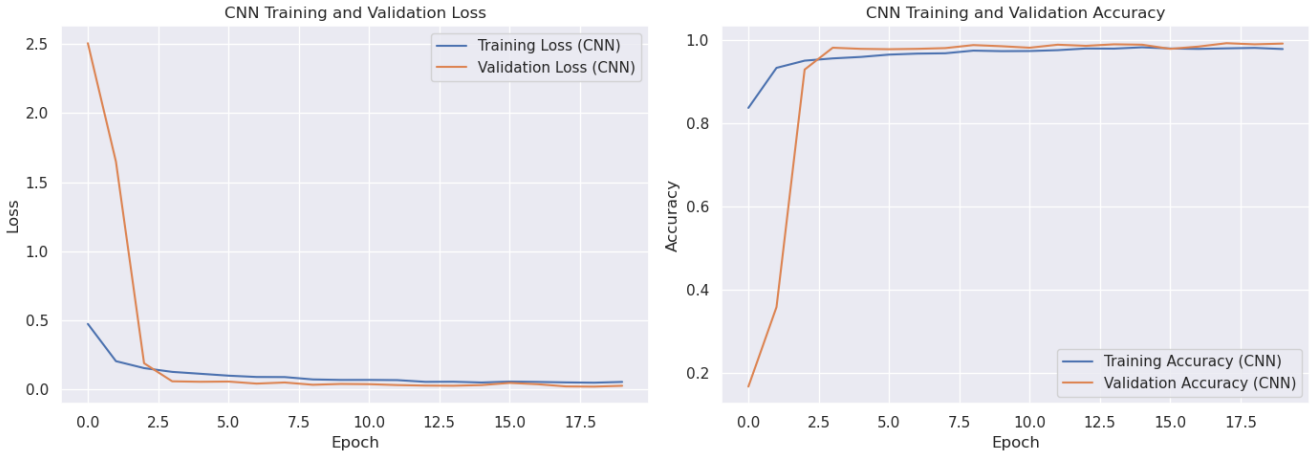
در این بخش به بررسی ساختار شبکه‌ی CNN طراحی‌شده برای طبقه‌بندی فعالیت‌های انسانی بر اساس داده‌های سنسوری می‌پردازیم:

- **شکل ورودی** :مدل ورودی‌هایی با ۵۶۱ ویژگی دارد که به‌عنوان توالی زمانی در نظر گرفته می‌شوند. برای اینکه لایه‌های Conv1D بتوانند داده را پردازش کنند، ابتدا از لایه‌ی Reshape برای تبدیل شکل داده‌ها از (samples, 561) به (samples, 561, 1) استفاده شده است. این تبدیل به شبکه می‌گوید که داده شامل ۵۶۱ گام زمانی (timestep) است، که در هر گام فقط یک ویژگی وجود دارد.
- **لایه‌های کانولوشنی**
  - بلوک اول: شامل یک لایه Conv1D با ۶۴ فیلتر و کرنل سایز ۳ است، که پس از آن نرمال‌سازی (Batch Normalization)، تابع فعال‌سازی ReLU، لایه‌ی MaxPooling1D برای کاهش ابعاد و Dropout با نرخ ۰,۲۵ قرار گرفته است.
  - بلوک دوم: مشابه بلوک اول، با این تفاوت که تعداد فیلترها ۱۲۸ است.

این لایه‌ها به مدل اجازه می‌دهند الگوهای زمانی یا وابستگی‌های متوالی در داده‌ها (مثل تکرار حرکت یا تغییرات سیگنال) را بیاموزد، درست همان‌طور که CNN های دوبعدی لبه‌ها و بافت‌ها را در تصاویر تشخیص می‌دهند.

- **لایه‌ی تخت‌سازی (Flatten)** خروجی لایه‌های کانولوشنی به شکل دوبعدی است، که قبل از ورود به لایه‌های Dense باید با لایه‌ی Flatten تبدیل به یک بردار یک‌بعدی شود.
- **لایه‌های Fully Connected (Dense)** یک لایه Dense با ۶۴ نورون استفاده شده است که شامل نرمال‌سازی، تابع ReLU و Dropout با نرخ ۰,۵ برای جلوگیری از بیش‌برازش است.
- **لایه‌ی خروجی** :در پایان، یک لایه‌ی Dense با ۶ نورون و تابع فعال‌سازی softmax قرار دارد که برای **طبقه‌بندی چندکلاسه** مناسب است و خروجی را به احتمال تعلق به هر کلاس تبدیل می‌کند.

در ادامه مانند شبکه MLP، نمودارهای دقت و خطا و بقیه پارامترهای ارزیابی آورده شده‌است:



شکل ۱-۵ نمودارهای خطا و دقت برای مدل CNN

```
CNN Test Loss: 0.1331
CNN Test Accuracy: 0.9562

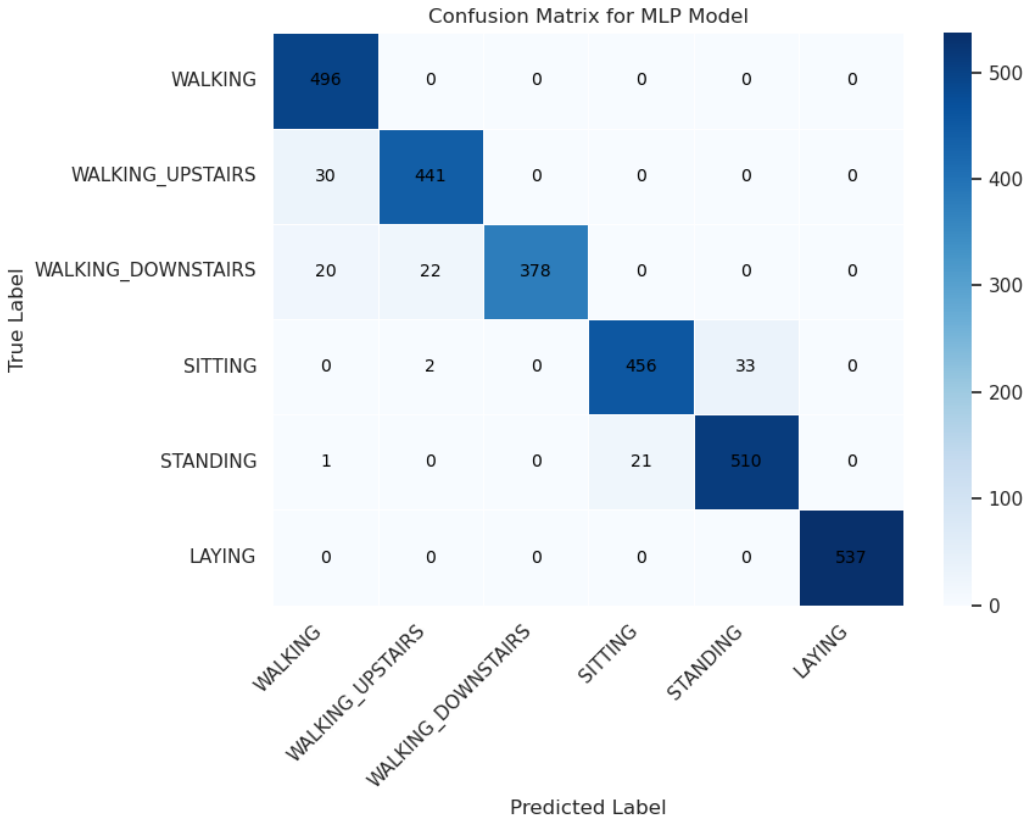
--- CNN Detailed Classification Report ---
                    precision    recall  f1-score   support

           WALKING       0.91      1.00      0.95       496
  WALKING_UPSTAIRS       0.95      0.94      0.94       471
WALKING_DOWNSTAIRS       1.00      0.90      0.95       420
           SITTING       0.96      0.93      0.94       491
          STANDING       0.94      0.96      0.95       532
            LAYING       1.00      1.00      1.00       537

          accuracy                           0.96      2947
         macro avg       0.96      0.95      0.96      2947
      weighted avg       0.96      0.96      0.96      2947


CNN Overall Test Accuracy (from sklearn): 0.9562
CNN Weighted Precision: 0.9578
CNN Weighted Recall: 0.9562
CNN Weighted F1-Score: 0.9562
```

شکل ۱-۶ دقت مدل CNN روی داده‌های Test



شکل ۱-۷ ماتریس آشفتگی برای مدل CNN

۱-۵ تحلیل و مقایسه دو مدل

هر دو مدل شبکه عصبی پرسپترون چندلایه (MLP) و شبکه عصبی کانولوشنی (CNN) عملکرد بسیار خوبی روی دیتاست UCI Human Activity Recognition (HAR) نشان می‌دهند. با وجود شباهت در دقت بالا، تفاوت‌هایی قابل توجه در معماری، کارایی، و نقاط قوت آن‌ها وجود دارد:

- **عملکرد کلی (دقت و خطا)**

MLP

- خطای تست: ۰,۱۱۸۴
- دقت تست: ۰,۹۶۱۰
- امتیاز F1 وزنی: ۰,۹۶۱۰

CNN

- خطای تست: ۰,۱۳۳۱
- دقت تست: ۰,۹۵۶۲
- امتیاز F1 وزنی: ۰,۹۵۶۲

مدل MLP از نظر دقت کلی تست و امتیاز F1 عملکرد بهتری نسبت به CNN دارد و حدود ٪۰,۵ دقت بالاتری دارد. همچنین خطای تست کمتری دارد که نشان‌دهنده‌ی برازش بهتر مدل روی توزیع داده‌های تست است.

- پیچیدگی مدل (تعداد پارامترها)

MLP

- تعداد کل پارامترها: ۱۷۷٬۵۴۲
- پارامترهای قابل آموزش: ۱۷۷٬۵۴۲

CNN

- تعداد کل پارامترها: ۱٬۱۷۳٬۳۱۸
- پارامترهای قابل آموزش: ۱٬۱۷۲٬۸۰۶

مدل CNN به‌طور قابل توجهی پیچیده‌تر از MLP است و حدود ۶,۶ برابر پارامترهای قابل آموزش بیشتری دارد. این تفاوت عمدتاً به دلیل استفاده از فیلترهای کانولوشنی و مرحله‌ی تخت‌سازی (Flatten) نگاشت‌های ویژگی قبل از ورود به لایه‌های Dense نهایی است. همچنین لایه‌های Batch Normalization تعداد کمی پارامتر غیربازآموزی‌پذیر (میانگین و واریانس) اضافه می‌کنند.

- نتیجه‌گیری

هر دو مدل برای دیتاست UCI HAR بسیار مؤثر هستند. مدل MLP با دقت و عملکرد اندکی بهتر، در کنار معماری جمع‌وجورتر (پارامترهای بسیار کمتر)، گزینه‌ی کارآمدتری در این مقایسه محسوب می‌شود.

مدل CNN نیز با وجود پیچیدگی بیشتر، عملکرد قابل قبولی دارد و توانایی آن برای کار روی داده‌های ساخت‌یافته‌ی غیرتصویری را اثبات می‌کند. قدرت واقعی آن زمانی آشکار می‌شود که با داده‌های خام سری‌زمانی یا همان داده‌های Inertial موجود در دیتاست آموزش داده شوند.

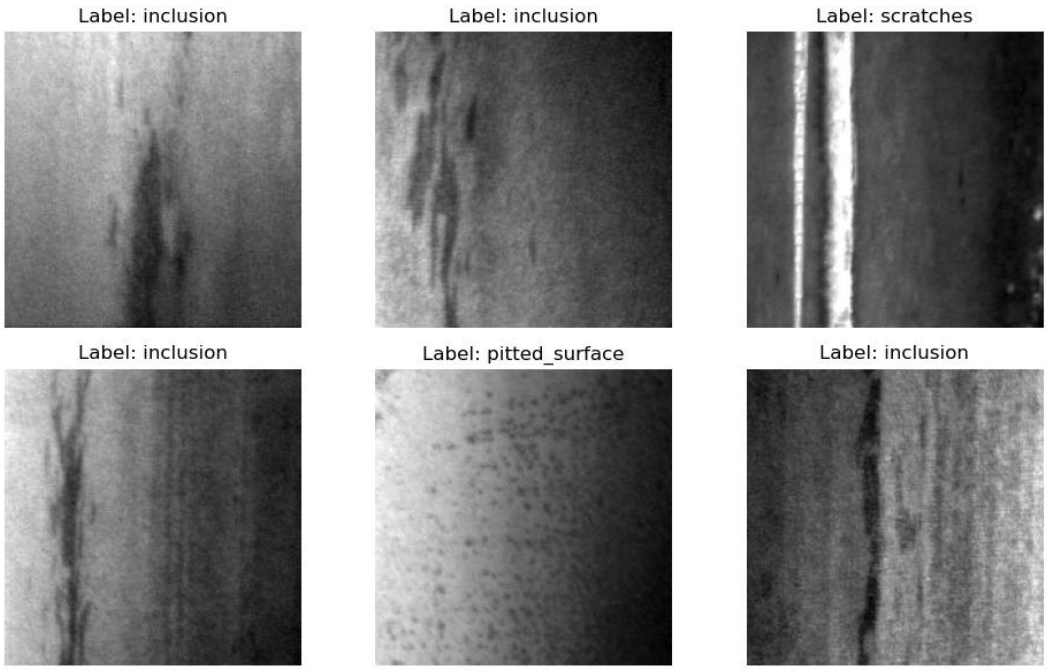
۲- دادگان NEU Surface Dataset

۲-۱ آماده‌سازی داده‌ها

مانند سری قبل، ابتدا تمامی داده‌ها به ۳ قسمت آموزش یا Train، Validation و Test با نسبت‌های ۷۰ به ۱۵ به ۱۵ تقسیم شده‌اند. در ادامه داده‌ها از طریق Min-Max-Scaling نرمال شده‌اند. از آنجا که جنس داده‌های این قسمت از نوع تصویر می‌باشد، برای نرمال‌سازی داده‌ها کافی است تا مقادیر آنها بر ۲۵۵ تقسیم شوند.

```
Found 360 files belonging to 6 classes.
Detected classes: ['crazing', 'inclusion', 'patches', 'pitted_surface', 'rolled-in_scale', 'scratches']
Number of classes: 6
X_train shape: (1260, 200, 200, 1), y_train shape: (1260,)
X_val shape: (270, 200, 200, 1), y_val shape: (270,)
X_test shape: (270, 200, 200, 1), y_test shape: (270,)
```

شکل ۲-۱ ابعاد و تعداد داده‌های هر بخش دادگان NUE



شکل ۲-۲ تعدادی نمونه از دادگان NEU Surface Dataset

۲-۲ طراحی شبکه MLP

در بخش اول، یک شبکه عصبی پرسپترون چندلایه برای طبقه‌بندی تصاویر در دیتاست پیاده‌سازی شده است. برخلاف مدل‌های رایج مبتنی بر شبکه‌های کانولوشنی که اطلاعات مکانی تصویر را حفظ می‌کنند، مدل MLP ابتدا تصویر را به یک بردار یک‌بعدی تبدیل کرده و سپس این بردار را به لایه‌های بعدی انتقال می‌کند و این نکته باید در طراحی لایه ورودی MLP رعایت شود:

شکل ورودی:

مدل ورودی‌هایی با ابعاد تصویری (IMG_HEIGHT, IMG_WIDTH, 1) دریافت می‌کند، که نشان‌دهنده‌ی تصاویر سیاه‌وسفید (تک‌کاناله) با ارتفاع و عرض مشخص هستند. برای اینکه مدل MLP بتواند داده‌ی تصویری را پردازش کند، ابتدا با استفاده از لایه‌ی Flatten شکل داده از (ارتفاع، عرض، ۱) به یک بردار یک‌بعدی تبدیل می‌شود. این بردار تمامی پیکسل‌های تصویر را به‌صورت یک توالی متوالی به مدل منتقل می‌کند.

لایه‌های پنهان:(Fully Connected Blocks)

این شبکه شامل چهار بلوک چگال (Dense) متوالی است:

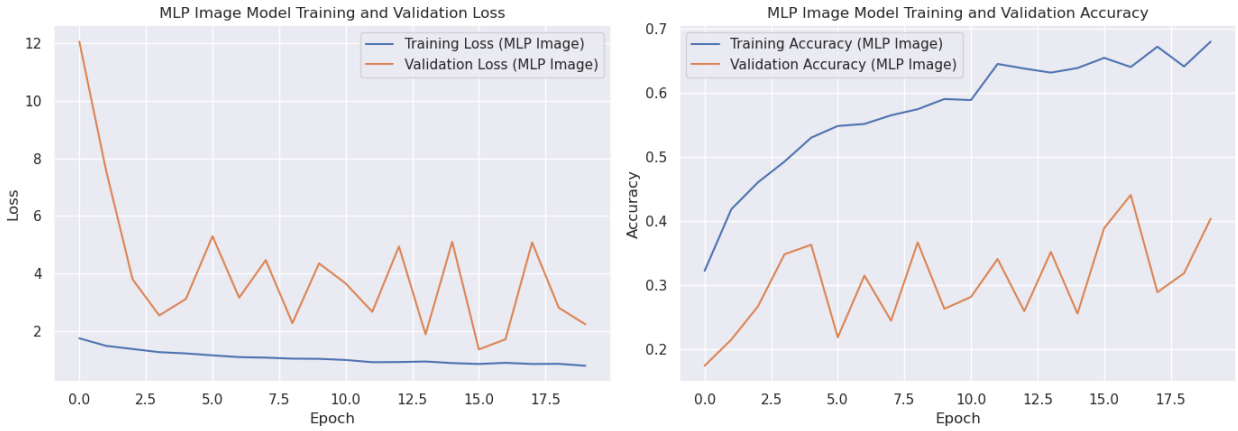
- **بلوک اول** :شامل یک لایه Dense با ۱۰۲۴ نرون است که پس از آن نرمال‌سازی (BatchNormalization)، تابع فعال‌سازی ReLU و Dropout با نرخ ۰,۴ قرار گرفته است.
- **بلوک دوم** :مشابه بلوک اول، اما تعداد نرون‌ها ۵۱۲ است و همان ترکیب نرمال‌سازی، ReLU و Dropout با نرخ ۰,۴ استفاده شده است.
- **بلوک سوم** :با ۲۵۶ نرون، نرمال‌سازی، تابع ReLU و Dropout با نرخ ۰,۳.
- **بلوک چهارم** :شامل ۱۲۸ نرون است که مجدداً با نرمال‌سازی، تابع ReLU و Dropout با نرخ ۰,۳ دنبال شده است.

هدف این بلوک‌ها استخراج ویژگی‌های سطح بالاتر از تصویر تخت‌شده و کاهش تدریجی ابعاد بردار ویژگی است.

لایه‌ی خروجی:

در پایان، یک لایه‌ی Dense با تعداد نرون برابر با تعداد کلاس‌های موجود در دیتاست قرار دارد که از تابع فعال‌سازی softmax استفاده می‌کند. این تابع خروجی مدل را به احتمال تعلق به هر کلاس تبدیل می‌کند و برای مسائل طبقه‌بندی چندکلاسه مناسب است.

نمودارهای خطا و دقت و بقیه معیارهای ارزیابی طبق مدل‌های قبلی آورده شده‌اند:



شکل ۲-۳ نمودارهای خطا و دقت برای مدل MLP

```
MLP Image Model Test Loss: 2.6033
MLP Image Model Test Accuracy: 0.3926
                precision    recall  f1-score   support

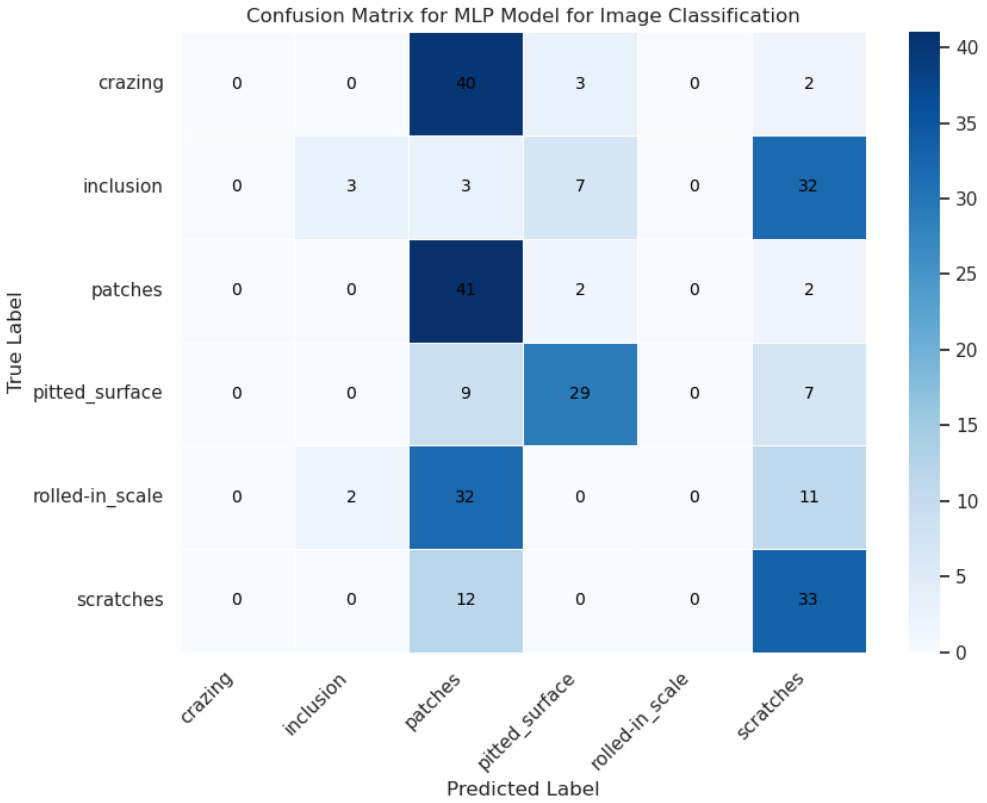
       crazing       0.00      0.00      0.00        45
     inclusion       0.60      0.07      0.12        45
       patches       0.30      0.91      0.45        45
  pitted_surface       0.71      0.64      0.67        45
rolled-in_scale       0.00      0.00      0.00        45
     scratches       0.38      0.73      0.50        45

      accuracy                           0.39       270
     macro avg       0.33      0.39      0.29       270
  weighted avg       0.33      0.39      0.29       270


MLP Image Model Overall Test Accuracy (from sklearn): 0.3926
MLP Image Model Weighted Precision: 0.3310
MLP Image Model Weighted Recall: 0.3926
MLP Image Model Weighted F1-Score: 0.2908
```

شکل ۲-۴ دقت مدل MLP روی داده‌های Test برای دسته‌بندی تصاویر

همانطور که مشاهده می‌شود دقت این مدل حدودا ۴۰ درصد بوده که نتیجه ضعیفی به حساب می‌آید. این موضوع با توجه به اینکه شبکه‌های MLP قادر به درک اطلاعات محلی پیکسل‌های مجاور یکدیگر در تصاویر نمی‌باشند، پیش‌بینی می‌شد.



شکل ۲-۵ ماتریس آشفتگی برای مدل MLP

همانطور که از ماتریس آشفتگی پیداست، این مدل در برخی کلاس‌ها از جمله rolled-in به هیچ‌وجه توانایی پیش بینی را نداشته و امید است که مدل CNN بتواند نقوص مدل MLP را جبران کند.

۲-۳ طراحی شبکه CNN ابتدایی

شکل ورودی:

ورودی مدل دارای ابعاد (IMG_HEIGHT, IMG_WIDTH, 1) است، که نشان‌دهنده‌ی تصاویر تک‌کاناله‌ی خاکستری با اندازه‌ی مشخص هستند. این فرمت برای لایه‌ی کانولوشن دوبعدی (Conv2D) مناسب است و به مدل اجازه می‌دهد ویژگی‌های مکانی (نظیر لبه‌ها، بافت‌ها و الگوهای سطحی) را از تصویر استخراج کند. این امر اجازه می‌دهد که نقوص مدل MLP تا حد بسیار زیادی جبران شود.

لایه‌های پنهان:(Convolutional Blocks)

این شبکه شامل **سه بلوک کانولوشنی** است که هرکدام الگوهای سطحی پیچیده‌تری را از تصویر استخراج می‌کنند:

- **بلوک اول:**
  - لایه‌ی Conv2D با ۳۲ فیلتر و کرنل سایز ۳×۳ با padding از نوع 'same' که شکل خروجی را حفظ می‌کند.

- نرمال‌سازی دسته‌ای (BatchNormalization) برای پایدارسازی فرآیند آموزش.
- تابع فعال‌سازی .ReLU
- لایه‌ی MaxPooling2D با کرنل ۲×۲ برای کاهش ابعاد مکانی.
- Dropout با نرخ ۰,۲۵ برای جلوگیری از بیش‌برازش یا Overfitting.

- **بلوک دوم:**
  - مانند بلوک اول، اما با ۶۴ فیلتر در لایه‌ی کانولوشن.
  - سایر مراحل که مشابه لایه کانولوشنی قبل هستند.
- **بلوک سوم:**
  - لایه‌ی کانولوشن با ۱۲۸ فیلتر.
  - سایر مراحل.

لایه‌ی تخت‌سازی:(Flatten)

پس از استخراج ویژگی‌ها توسط لایه‌های کانولوشنی، خروجی آن‌ها که به‌صورت سه‌بعدی است به کمک لایه‌ی Flatten به یک بردار اطلاعات تخت تبدیل می‌شود.

لایه‌ی:Fully Connected (Dense)

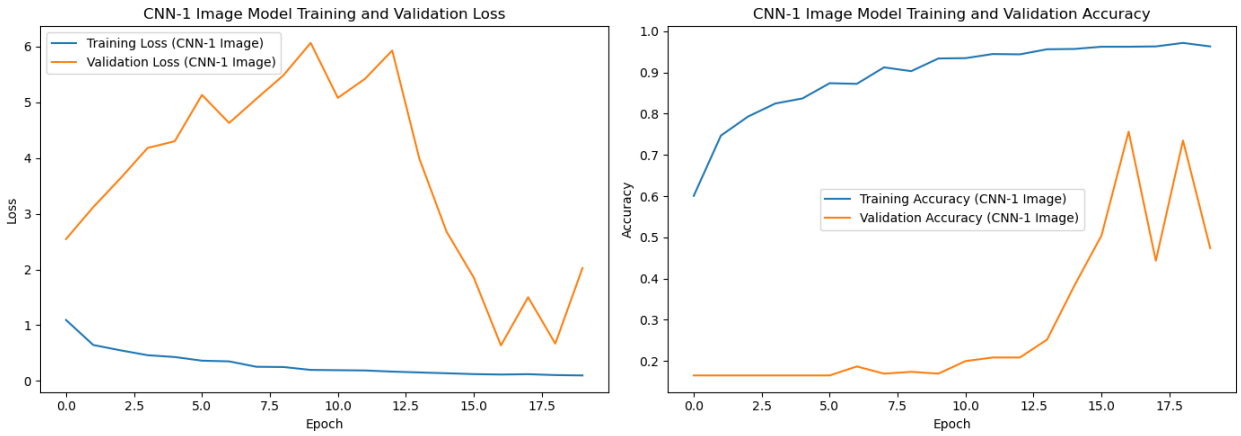
پس از تخت‌سازی، یک لایه‌ی Dense با ۱۲۸ نورون به‌کار گرفته شده است.

- این لایه دارای تابع فعال‌سازی ReLU است.
- شامل BatchNormalization و Dropout با نرخ ۰,۵ برای جلوگیری از بیش‌برازش می‌باشد.

لایه‌ی خروجی:

در پایان، یک لایه‌ی Dense با تعداد نورون برابر با تعداد کلاس‌ها (۶ کلاس) قرار گرفته است که از تابع فعال‌سازی softmax استفاده می‌کند. این تابع، بردار خروجی را به احتمال تعلق به هر کلاس تبدیل می‌کند و برای مسائل طبقه‌بندی چندکلاسه بسیار مناسب است.

نتایج ارزیابی و نمودارهای این مدل در ادامه آورده شده‌است:



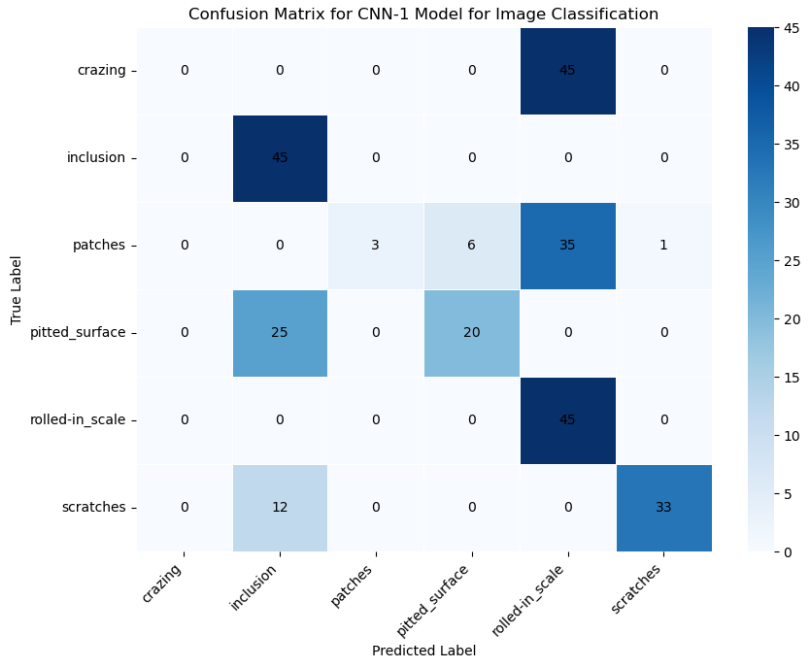
شکل ۲-۶ نمودارهای دقت و خطا برای شبکه CNN

```
CNN-1 Image Model Test Loss: 1.8384
CNN-1 Image Model Test Accuracy: 0.5407
                precision    recall  f1-score   support

       crazing       0.00      0.00      0.00        45
     inclusion       0.55      1.00      0.71        45
       patches       1.00      0.07      0.12        45
  pitted_surface       0.77      0.44      0.56        45
rolled-in_scale       0.36      1.00      0.53        45
     scratches       0.97      0.73      0.84        45

      accuracy                           0.54       270
     macro avg       0.61      0.54      0.46       270
  weighted avg       0.61      0.54      0.46       270
```

شکل ۲-۷ دقت مدل CNN روی داده‌های Test



شکل ۲-۸ ماتریس آشفتگی برای مدل CNN

همانطور که دیده می‌شود دقت مدل CNN ساده روی داده‌های تست حدودا ۵۴ درصد می‌باشد. هرچند که این دقت نسبت به مدل MLP جهشی بزرگ به حساب می‌آید، اما به هیچ عنوان راضی‌کننده نیست.

در قسمت بعد سعی می‌شود تا با تنظیم هایپرپارامترها و بهبود مدل، دقت افزایش یابد.

۲-۴ طراحی شبکه CNN بهینه

برای بهبود مدل، از روش‌های زیر استفاده شده است:

۱- استفاده از Block Dropout بجای Dropout: در Dropout معمولی، نورون‌ها به‌صورت تصادفی و مستقل غیرفعال می‌شوند. اما در **Block Dropout**، به‌جای خاموش‌کردن نورون‌های منفرد، **بخش‌هایی پیوسته (بلوک‌های مکانی) از ویژگی‌ها** غیرفعال می‌شوند.

مزیت‌ها:

- در لایه‌های کانولوشنی، فعال‌سازی‌ها دارای ساختار مکانی هستند .Dropout معمولی با از بین بردن فعال‌سازی‌های تصادفی، به این ساختار آسیب می‌زند.
- Block Dropout نواحی پیوسته را حذف می‌کند، که باعث می‌شود مدل از اتکا به الگوهای محلی خاص اجتناب کرده و ویژگی‌های پراکنده‌تری را یاد بگیرد.
- به‌ویژه در مدل‌های بینایی مانند همین تمرین، این روش به **افزایش مقاومت مدل در برابر مکان‌پذیری و تغییرات موضعی در بافت تصویر** کمک می‌کند.

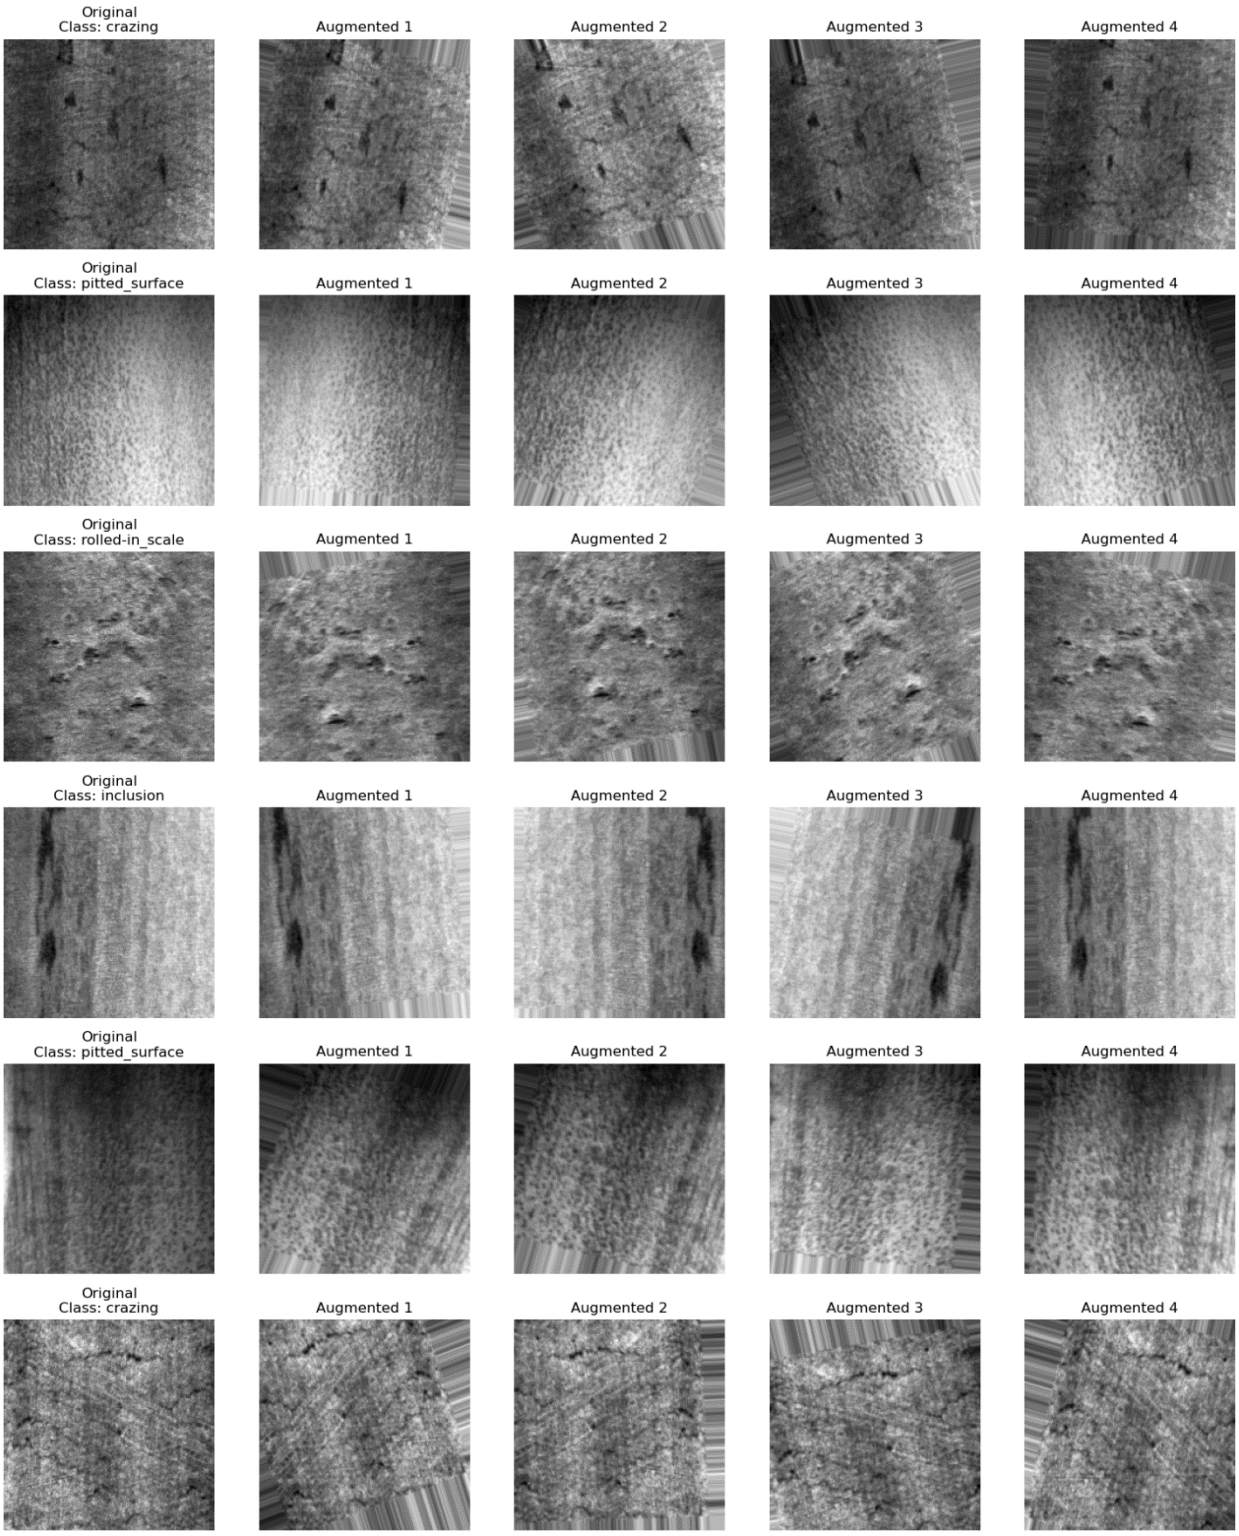
۲- استفاده از تجزیه فیلترها یا Kernel Factorization: در این روش، به‌جای استفاده از کرنل‌های دوبعدی بزرگ (مثلاً ۵×۵)، از ترکیب دو یا چند کرنل کوچکتر استفاده می‌شود. برای مثال، یک کرنل ۵×۵ را می‌توان به دو کرنل ۵×۱ و ۱×۵ تجزیه کرد.

مزیت‌ها:

- **کاهش پارامترها :**به‌جای ۲۵ وزن برای یک کرنل ۵×۵، در factorization تنها ۱۰ وزن نیاز است.
- **کاهش بار محاسباتی :**موجب تسریع آموزش و کاهش نیاز به حافظه می‌شود.
- **حفظ قدرت بیان مدل :**به‌رغم کاهش پارامترها، مدل همچنان می‌تواند الگوهای پیچیده را یاد بگیرد، زیرا ترکیب کرنل‌های یک‌بعدی اثر مشابه کرنل‌های بزرگ‌تر را دارد.

۳- استفاده از روش داده‌افزایی یا Data Augmentation: در این تکنیک، با اعمال تغییرات تصادفی روی تصاویر آموزشی (مثل چرخش، برش، زوم، تغییر روشنایی، قرینه‌سازی، نویزگذاری و ...) مجموعه داده را بزرگ‌تر و متنوع‌تر می‌کنیم، بدون اینکه به داده‌ی واقعی جدید نیاز داشته باشیم.

در شکل زیر نمونه‌هایی از تصاویر اصلی و تصاویر اضافی تولیدشده آورده شده‌است:

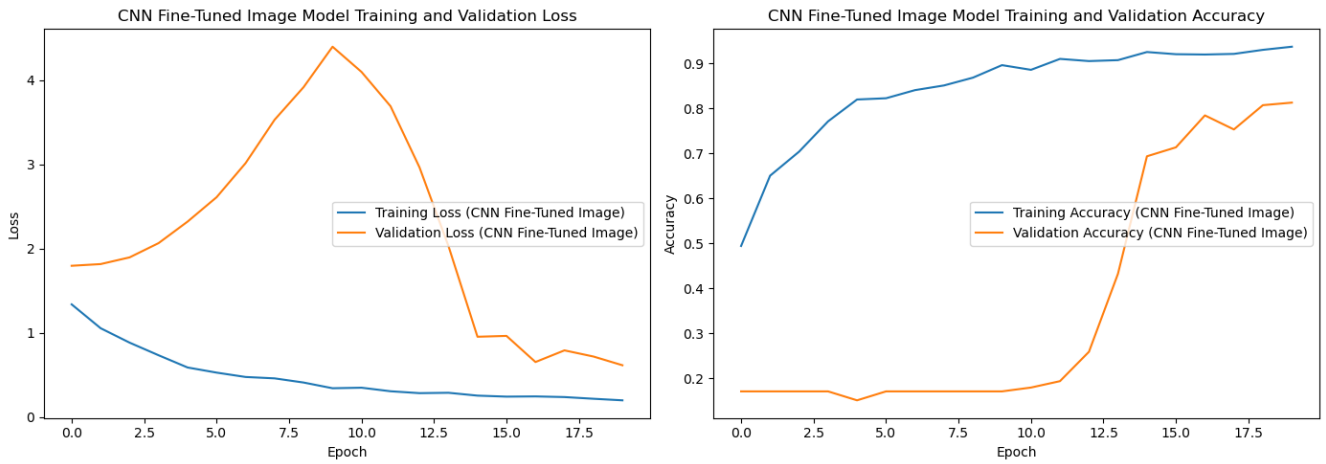


شکل ۲-۹ نمونه‌هایی از تصاویر دیتاست به همراه نسخه‌های Augment شده

لازم بذکر است که برای داده‌افزایی از روش‌های معمول مانند تغییر زاویه، تغییر شدت رنگ، شیفت تصویر در

راستاهای عمودی و افقی و غیره استفاده شده است.

در ادامه نمودارها و ارزیابی‌های مدل CNN بهینه‌شده آورده شده‌است:



شکل ۲-۱۰ نمودارهای خطا و دقت برای مدل CNN بهینه‌شده

```
CNN Fine-Tuned Image Model Test Loss: 0.5071
CNN Fine-Tuned Image Model Test Accuracy: 0.8407
                precision    recall  f1-score   support

       crazing       0.80      1.00      0.89        45
     inclusion       0.81      0.87      0.84        45
       patches       1.00      0.80      0.89        45
 pitted_surface      1.00      0.51      0.68        45
rolled-in_scale      0.85      1.00      0.92        45
     scratches       0.72      0.87      0.79        45

      accuracy                           0.84       270
     macro avg       0.86      0.84      0.83       270
  weighted avg       0.86      0.84      0.83       270


CNN Fine-Tuned  Image Model Overall Test Accuracy (from sklearn): 0.8407
CNN Fine-Tuned Image Model Weighted Precision: 0.8646
CNN Fine-Tuned Image Model Weighted Recall: 0.8407
CNN Fine-Tuned Image Model Weighted F1-Score: 0.8336
```

شکل ۲-۱۱ دقت مدل CNN بهینه‌شده روی داده‌های Test

همانطور که مشاهده می‌شود با بهینه‌سازی در ساختار شبکه و افزایش داده‌ها، دقت از ۵۵ به حدود ۸۴ درصد رسیده است.

لازم به ذکر است که ساختار اصلی شبکه از جمله تعداد لایه‌ها و نورون‌ها دست‌نخورده باقی‌مانده است.

در ادامه برای رسیدن به حداکثر دقت، از مدل‌هایی پیچیده با ضرایب وزنی آموزش دیده‌شده استفاده می‌شود.

۲-۵ طراحی شبکه ResNet-50

ابتدا نیاز است تا شکل داده‌های ورودی مطابق شبکه موردنظر در آمده و سپس بر اساس تعداد لایه‌های موردنظر، فریزینگ انجام شده و لایه آخر به شبکه اضافه شود. برای این کار مراحل زیر طی می‌شود:

پیش‌پردازش داده‌ها:

برای انطباق با نیازهای معماری ResNet ، که برای تصاویر رنگی طراحی شده است، ابتدا تصاویر خاکستری به تصاویر رنگی (RGB) تبدیل شده‌اند. این کار با **تکرار کانال خاکستری سه بار در بعد کانال‌ها** انجام شده تا شکل ورودی به (۲۰۰, ۲۰۰, ۳) تبدیل شود. همچنین، برچسب‌های داده به صورت **کدگذاری one-hot** درآمده‌اند تا برای یادگیری چندکلاسه مناسب باشند.

لایه‌ی پایه:(Base Model)

مدل پایه، معماری **ResNet-50V2**است که یک شبکه‌ی عمیق و قدرتمند کانولوشنی می‌باشد. این مدل با تنظیم include_top=False بارگذاری شده است، یعنی لایه‌های Fully Connected نهایی آن حذف شده‌اند تا بتوان از آن به‌عنوان استخراج‌کننده‌ی ویژگی استفاده کرد.

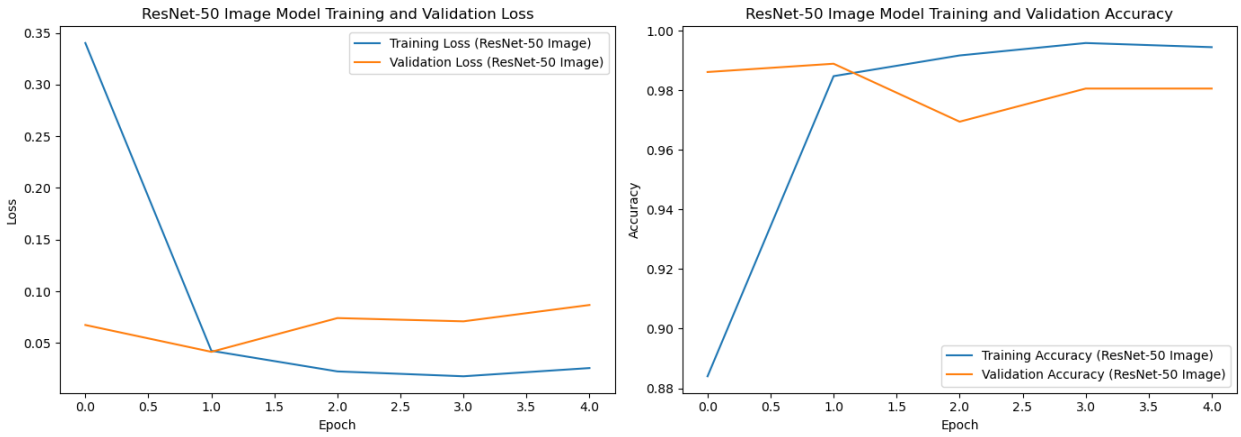
وزن‌های مدل از فایل **پیش‌آموزش‌شده‌ی بدون لایه‌ی top** بارگذاری شده‌اند. سپس تمام لایه‌های ResNet قفل (Freeze) شده‌اند تا حین آموزش تغییر نکنند؛ در نتیجه، ویژگی‌های تعمیم‌پذیر آموزش‌دیده‌ی قبلی حفظ می‌شوند.

معماری نهایی مدل:

پس از لایه‌ی پایه، از یک ساختار ساده‌ی Fully Connected برای طبقه‌بندی استفاده شده است:

- **GlobalAveragePooling2D** برای تبدیل خروجی‌های مکانی به یک بردار ویژگی استفاده شده است.
- سپس دو لایه‌ی Dense با ۵۱۲ و ۲۵۶ نورون قرار گرفته‌اند که هرکدام دارای تابع فعال‌سازی ReLU و Dropout به ترتیب با نرخ ۰,۵ و ۰,۳ هستند.
- در پایان، یک لایه‌ی خروجی Dense با تعداد نورون برابر با تعداد کلاس‌ها و تابع فعال‌سازی Softmax برای طبقه‌بندی چندکلاسه قرار دارد.

لازم به ذکر است که بدلیل قدرت این مدل، تنها ۵ epoch استفاده شده‌است:



شکل ۲-۱۲ نمودار خطا و دقت برای مدل ResNet-50

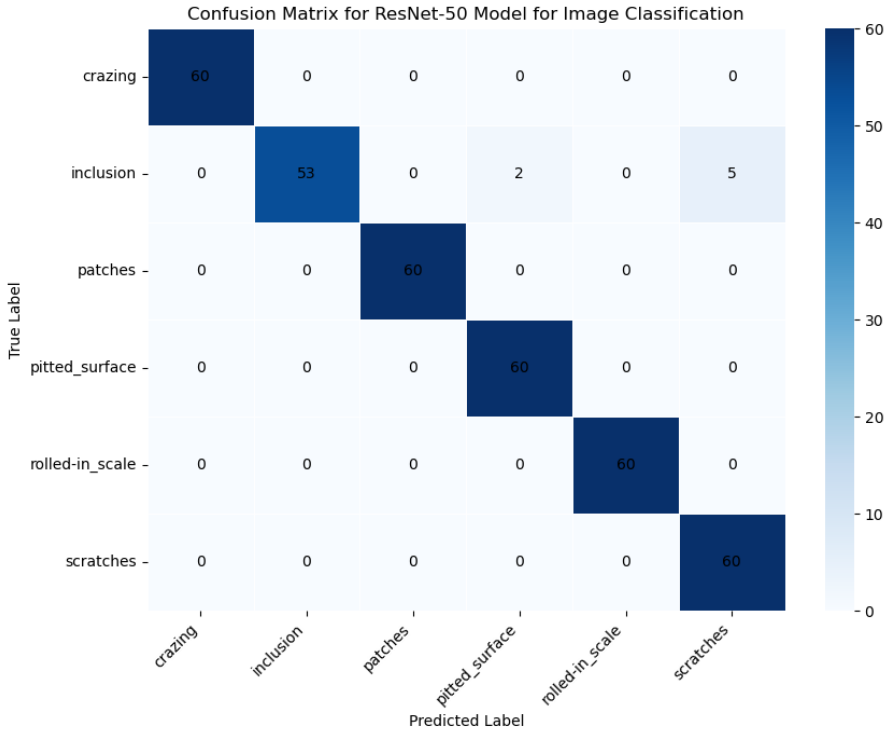
```
ResNet50 Fine-Tuned Model Test Loss: 0.0868
ResNet50 Fine-Tuned Model Test Accuracy: 0.9806
                precision    recall  f1-score   support

       crazing       1.00      1.00      1.00        60
     inclusion       1.00      0.88      0.94        60
       patches       1.00      1.00      1.00        60
 pitted_surface      0.97      1.00      0.98        60
rolled-in_scale      1.00      1.00      1.00        60
     scratches       0.92      1.00      0.96        60

      accuracy                           0.98       360
     macro avg       0.98      0.98      0.98       360
  weighted avg       0.98      0.98      0.98       360


ResNet50 Fine-Tuned Model Overall Test Accuracy (from sklearn): 0.9806
ResNet50 Fine-Tuned Model Weighted Precision: 0.9818
ResNet50 Fine-Tuned Model Weighted Recall: 0.9806
ResNet50 Fine-Tuned Model Weighted F1-Score: 0.9803
```

شکل ۲-۱۳ دقت مدل ResNet-50 روی داده‌های Test



شکل ۲-۱۴ ماتریس آشفتگی برای مدل ResNet-50

۲-۵ مقایسه مدل‌ها

در این پروژه، چهار مدل مختلف برای تشخیص عیوب سطحی از تصاویر آموزش داده شده‌اند: یک مدل **MLP**، یک **شبکه کانولوشنی ساده (Simple CNN)** ، یک **شبکه CNN بهینه‌شده با داده‌افزایی(Optimized CNN)** ، و یک **مدل از پیش آموزش‌دیده‌ی ResNet50**. در ادامه عملکرد هر مدل را از جنبه‌های مختلف بررسی می‌کنیم.

- **دقت و عملکرد**

مدل MLP با وجود داشتن بیش از ۴۱ میلیون پارامتر، تنها به دقتی حدود ٪۳۹ دست یافت. این ضعف ناشی از ساختار خطی آن و عدم توانایی در استخراج ویژگی‌های مکانی از تصویر است. مدل CNN ساده با دقتی حدود ٪۵۴ عملکرد بهتری داشت، اما همچنان در شناسایی برخی کلاس‌ها ضعیف بود.

مدل CNN بهینه‌شده با استفاده از تکنیک‌های داده‌افزایی، با وجود داشتن تنها حدود ۲۰ هزار پارامتر، دقت چشمگیری معادل ٪۸۴ به‌دست آورد و تعادلی عالی بین کارایی و سادگی ایجاد کرد. در نهایت، مدل ResNet50 با انتقال یادگیری (transfer learning) از شبکه‌ای که قبلاً روی ImageNet آموزش دیده بود، دقتی نزدیک به ٪۹۸ را نشان داد و تقریباً در تمام کلاس‌ها عملکردی بی‌نقص داشت.

- **پیچیدگی و منابع مصرفی**

از نظر پیچیدگی، مدل MLP با بیشترین تعداد پارامترها (بیش از ۴۱ میلیون) پیچیده‌ترین و در عین حال ناکارآمدترین مدل بود CNN .ساده با حدود ۱۰ میلیون پارامتر سبک‌تر است، اما هنوز نسبت به عملکردش سنگین محسوب می‌شود.

در مقابل، CNN بهینه‌شده بسیار سبک است و با حدود ۲۰ هزار پارامتر، بالاترین نسبت دقت به پیچیدگی را دارد. این سبک بودن ناشی از استفاده از Kernel Factorization می‌باشد. مدل ResNet50 با وجود داشتن ۲۴ میلیون پارامتر، فقط حدود ۱,۱۸ میلیون پارامتر قابل آموزش داشت، زیرا بخش اعظم مدل (Feature Extractor) فریز شده بود؛ بنابراین با وجود پیچیدگی ظاهری، آموزش آن نسبتاً بهینه بود.

- **سرعت و زمان اجرا**

از نظر سرعت اجرا و آموزش، MLP به‌دلیل تعداد زیاد پارامترها و نداشتن ساختار بهینه کندتر عمل می‌کند . CNNساده عملکرد متوسطی دارد CNN .بهینه‌شده سریع‌ترین مدل از نظر زمان آموزش و اجرای inference است و به‌راحتی قابل پیاده‌سازی در سیستم‌های سبک مانند موبایل یا میکروکنترلرهاست.

مدل ResNet50 نیاز به حافظه و منابع محاسباتی بالا دارد، اما به‌لطف انتقال یادگیری و فریز بودن بیشتر لایه‌ها، زمان آموزش آن نسبتاً کم و inference آن در سطح قابل قبول است.

- **تعمیم‌پذیری و قدرت شناسایی کلاس‌ها**

از نظر قدرت تعمیم، مدل ResNet50 بهترین عملکرد را دارد، زیرا از داده‌های متنوع و پیچیده‌ی دیتاست ImageNetآموخته و در کلاس‌های مختلف نتایج بسیار دقیقی ارائه می‌دهد CNN .بهینه‌شده نیز با بهره‌گیری از داده‌افزایی و طراحی مناسب، تعمیم‌پذیری خوبی دارد.

در مقابل، MLP و CNN ساده به‌ویژه در کلاس‌های کم‌نمونه یا پیچیده)مانند crazing یا rolled-in scale عملکرد ضعیف‌تری نشان می‌دهند و تعادل بین کلاس‌ها را رعایت نمی‌کنند.

در نهایت می‌توان ۴ مدل را طبق جدول زیر خلاصه و مقایسه کرد:

جدول ۲ مقایسه مدل‌ها در پروژه ۲

مدل/ معیار بررسی	MLP	Simple CNN	Fine-Tuned CNN	ResNet-50
دقت روی داده‌های تست	۳۹٪	۵۴٪	۸۴٪	۹۸٪
تعداد پارامترها	41.6M	10.3M	20K	24.7M (1.18 trainable)
تعادل بین کلاس‌ها	ضعیف	متوسط	خوب	عالی
قابلیت پیاده‌سازی بلادرنگ	خیر	خیر	بله	بله (فقط با GPU)

در نهایت می‌توان گفت اگر دقت بسیار بالا در نظر نباشد و دسترسی به GPU وجود نداشته باشد، مدل CNN بهینه‌شده انتخاب خوبی می‌باشد.